AI 기반 품질위험 회피형 홀로닉 자율제조 시스템:

항공기 구조물 무인 가공공장의 예측–설명–대응 폐루프 설계와 시뮬레이션 검증

AI-Based Quality-Risk-Averse Holonic Autonomous Manufacturing System: Design and Simulation-Based Validation of a Predict–Explain–Act Closed Loop for a Lights-Out Aircraft Structural Machining Factory

초 록

대상 항공기 구조물 무인 가공공장은 홀로닉 자율제조로 계획·실행·재스케줄링을 자율 수행하나 품질 폐루프는 측정 후 보정에 그친다. 기존 홀로닉 실행체계에 품질위험 예측·요인별 대응·사전 검증·실패 시 복구를 연결하는 폐루프 지능 계층을 제안한다. 보정 시뮬레이터의 고위험 조건에서 예방 교체 규칙 대비 이상률 16~21%(−2.3~−3.1%p)·공구 교체 약 12% 감소, 동일 셋업 정보 규칙 대비 정상 부하에서 이상률 1.2%p 감소를 보였으나(포화 비유의), 조정된 공정별 규칙 대비 추가 우위는 확인되지 않았고 포화·고위험에서는 규칙의 이상률이 더 낮았다. 예측기는 공개 밀링 데이터로 검증했고(구간 단위 AUC 0.89, 실험 단위 0.79), 장애 주입 SIL 시험으로 설계한 복구 동작을 확인했다.

Key Words : 홀로닉 제조시스템(Holonic Manufacturing System), 품질위험 예측(Quality Risk Prediction), 설명가능 인공지능(Explainable AI), 사이버물리시스템(Cyber-Physical System), 공구 마모(Tool Wear), 자율제조(Autonomous Manufacturing)

1. 서 론

항공기 주익 내부 구조물인 윙 리브류 대형 알루미늄 합금 부품은 5 축 정밀 가공으로 생산되며, 신제품이 드문 대신 지정된 제품을 수십 년간 동일한 품질로 생산해야 한다. 비계획 정지와 제어 오류가 품질·납기·설비 운영에 높은 비용을 유발하는 이 조건에서, 국내의 한 항공기 구조물 정밀가공 무인공장은 2016 년 설계부터 설비마다 독립된 프로세스를 심어 스스로 판단하고 협업하는 홀로닉 자율제조 시스템[1~3]을 구축하였다. 영업이 확정한 수주 정보 세 항목만 입력되면 생산계획부터 가공·이송·세척·검사·출하까지 시스템이 스스로 수립하고 실행하며, 생산부와 생산관리부 등 관리 조직 없이 10 년 가까이 운영되고 있다. 이 시스템은 이후 사이버물리시스템(CPS) 기반 분 단위 재스케줄링, 주말·야간 무인 운영, 그리고 3 차원 측정기(CMM) 결과를 온도 보정하여 가공 스케일로 되돌리는 품질 폐루프까지 갖추었다.

그러나 이 품질 폐루프는 측정 이후에 닫힌다. 검사에서 확인된 편차가 다음 부품의 보정값으로 반영되므로, 편차를 만든 부품은 이미 가공된 뒤이며 재작업 또는 폐기 판단이 뒤따른다. 항공 부품은 단가가 높고 재작업이 납기와 설비 가동률을 동시에 잠식하므로, 품질 관리의 다음 단계는 "다음 부품의 품질 위험을 가공 전에 알고, 자율제조의 의사결정에 반영하여 회피하는 것"이다. 이때 예측만으로는 충분하지 않다. 항공 구조물은 대형 소재 블록의 대부분을 깎아내는 포켓 가공이 많아 가공 중의 이상이 뒤틀림이나 치수 이탈로 이어지면 고가의 소재를 통째로 폐기해야 하는데, 이상 확률만으로는 공구 교체·셋업 재확인·재할당 가운데 어떤 대응을 택해야 하는지 결정하기 어렵다. 반면 위험의 기여 요인(이 공구의 누적 마모인지, 이 셋업의 클램프 압력인지)이 함께 제시되면 공구 교체나 셋업 재확인 같은 국소 조치로 가공을 이어갈 수 있다. 또한 항공 구조부품 정밀가공의 가공 조건 판단은 숙련 엔지니어의 경험에 의존해 왔으므로, 판단 근거가 데이터로 남는 구조는 그 묵시적 지식을 문서화된 기준으로 바꾸는 수단이기도 하다. 예측 결과가 공구 교체, 설비 재할당, 셋업 재확인과 같은 실제 의사결정으로 이어져야 하고, 그 판단의 근거가 추적 가능하고 담당자가 검토할 수 있어야 현장 적용 시 검증 가능성이 확보되며, 대응이 납기와 가동률을 해치지 않는다는 것을 적용 전에 확인할 수 있어야 한다.

이러한 요구는 최근의 설명가능 인공지능(XAI)[15~17]과 처방적 분석(prescriptive analytics)[18,19] 연구가 다루는 문제와 맞닿아 있으나, 기존 연구 대부분은 예측 정확도나 설명의 품질에서 멈추고, 실제 운영 중인 자율제조 시스템의 의사결정 구조에 연결하여 생산 지표로 효과를 검증한 사례는 드물다. 특히 홀로닉 제조시스템처럼 이미 검증된 분산 자율 실행 구조가 존재할 때, AI 가 그 구조를 대체하지 않고 어디에 어떤 형태로 얹혀야 안전하게 가치를 내는지에 대한 설계 원칙은 정립되어 있지 않다.

본 연구는 "이미 스스로 움직이는 공장"에 "가공 전에 위험을 예측하고 이유를 설명하며 대응을 검증하는" 판단 계층을 더하여, 자율 실행을 예측·설명형 자율 실행으로 확장하는 시스템을 제안한다. 연구 질문은 두 가지이다. (1) 기존 실행체계를 유지한 채 예측·대응·검증·복구를 연결하여 납기준수율과 가동률을 유지하면서 품질 이상을 사전에 회피할 수 있는가. (2) 그 정책 효과는 같은 정보를 갖는 규칙과 별도로 조정한 공정별 규칙을 넘어서는가. 본 연구의 기여는 세 가지이다. 첫째, 대상 공장의 기존 운영 구조에 명시적으로 통합되지 않았던 가공 전 품질위험 의사결정을 구현하는 설계이다. 기존 페루프는 측정 후 보정에서 닫히고 대응은 담당자 판단에 맡겨졌으나, 제안 계층은 실운영 중인 APS·홀론 실행 구조를 대체하지 않고 가공 직전의 위험 예측을 요인별 대응 후보, CPS 선행 검증, 기존 홀론 실행, CMM 피드백과 실패 시 계획 복구로 연결하여, 대응안이 적용 전에 검증되고 실행 실패 시 계획이 복원되는 8 단계 페루프를 만든다. 둘째, 그 효과가 어디까지 단순 규칙으로 달성되는지의 분리이다. 운영사 성과 지표로 보정한 시뮬레이터에서 기존 규칙, 제안과 같은 셋업 정보를 갖는 규칙, 별도 시드에서 조정한 공정별 임계 규칙과 30 회 짝지어 비교하여, 이득 가운데 정보·행동 조건에서 오는 부분과 제안 정책 전체의 추가분을 나누고 규칙으로 충분한 조건을 밝힌다. 셋째, 적용 범위의 검증이다. 셋업 관측 오류, 위험 함수 형태·예측기 품질의 불일치, 통신·실행 장애에서 효과의 유지 여부와 복구 동작을 확인한다. 공개 밀링 데이터로 실험 단위 교차검증과 누출 점검을 거친 예측기는 이 기여를 뒷받침하는 근거이다.

본 논문의 구성은 다음과 같다. 2 장에서 관련 연구를 정리하고, 3 장에서 대상 시스템과 문제를 정의한다. 4 장에서 제안 시스템을 설명하고, 5 장에서 데이터와 예측·설명 모델을 검증하며, 6 장에서 시뮬레이션 기반 시스템 검증 결과를 제시한다. 7 장에서 결과의 의미와 한계를 고찰하고 8 장에서 결론을 맺는다.

2. 관련 연구

2.1 홀로닉 제조시스템과 자율 실행

홀로닉 제조시스템(HMS)은 제품·자원·오더 홀론이 자율적으로 협상하며 생산을 수행하는 분산 제어 구조로, PROSA[1]와 ADACOR[2]로 이론이 정립되었고 홀로닉 제조실행시스템[3]과 에이전트 기반 분산 제어[4]로 발전하였다. 단일 실패점 위험을 완화한다는 점에서 중단이 허용되지 않는 항공 부품 가공에 적합하며, 본 연구의 대상 공장은 이 구조를 10 년 가까이 실운영한 사례이다. 다만 HMS 연구는 실행 구조의 견고성에 집중하였고, 홀론의 판단에 품질 예측과 같은 학습 기반 지능을 결합하는 문제는 덜 다루어졌다.

2.2 CPS·디지털 트윈 기반 계획–실행 동기화와 재스케줄링

CPS 기반 제조 구조[26]와 디지털 트윈은 실공장과 가상공장을 동기화하여 계획–실행 차이를 줄이고 변경안을 적용 전에 시험하는 수단으로 도입되어 왔다[5~8]. 동적 스케줄링과 재스케줄링 연구[9,10,27]는 설비 고장이나 긴급 수주에 대한 대응 전략을 체계화하였고, 최근에는 디지털 트윈과 AI 의 결합[36]과 해석 가능한 의사결정을 결합한 지능형 디지털 트윈[38]이 제안되었다. 이들은 트윈 안에서 예측과 해석을 의사결정에 연결하지만, 운영 중인 분산 실행 구조(홀론)를 보존한 채 검사 결과가 되돌아오는 폐루프까지 닫지는 않는다. 본 연구는 이 "적용 전 검증" 관행을 AI 가 생성한 대응안까지 확장한다.

2.3 공구 마모·품질 예측과 설명가능 인공지능

공구 마모는 가공 품질을 좌우하는 대표적 원인으로, PHM 2010 데이터 챌린지[11]와 NASA 밀링 데이터[12]가 절삭력·진동·전류 신호로 마모를 추정하는 연구의 표준 벤치마크가 되었고, 딥러닝 기반 설비 상태 감시[13,14]가 폭넓게 시도되었다. 그러나 대부분은 사후 추정 또는 잔여수명 예측에 머물며, 예측 품질(predictive quality) 연구[33]에서도 예측 이후의 의사결정 연계는 미개척 과제로 지적된다. SHAP[15,16] 등 XAI 기법은 제조 분야에 활발히 적용되고 있으나[17,34], 설명이 곧 행동으로 연결되는 구조는 드물다.

2.4 처방적 분석과 예측–행동 연결

처방적 분석은 예측을 넘어 취해야 할 행동을 제시하는 것을 목표로 하며, 제조 유지보수 분야를 중심으로 의사결정 방법이 정리되어 있다[18,19,35]. 본 연구는 처방적 분석의 관점을 품질 위험에 적용하되, 행동 후보를 XAI 의 위험 기여요인 설명에서 도출하고 사전 검증을 거쳐 실행한다는 점에서 차별된다.

Table 1. 가장 가까운 선행연구와 본 연구의 비교 (○ 확인, △ 부분적, × 다루지 않음이 명시됨, – 해당 문헌에서 확인되지 않음). 리뷰 문헌은 연구 동향의 근거로만 쓰였으며, 본 연구는 이들 구조를 대체하지 않고 그 위에 품질 판단을 얹는다

연구	기존 실행체계 보존	예측 후 대응 선택	동일 정보 규칙과 비교	실행 실패 시 계획 복구 시험	품질·공구 동시 평가
홀로닉 제조실행시스템 (3) — 분산 실행 구조의 견고성·자기 격리	○	×(규칙 기반 협상)	–	–	×
동적 재스케줄링 프레임워크 (27) — 고장·긴급 수주 대응 전략 체계화	△	○(재스케줄링)	–	–	–
지능형 디지털 트윈 (38) — ML 트윈 + 해석 가능한 의사결정	–	○	–	–	–
예측 품질·제조 XAI 리뷰 (33, 34) — 사전 품질 예측과 설명(동향 근거)	–	△(예측·설명까지)	–	–	–
처방적 분석·유지보수 리뷰 (18, 19, 35) — 예측→행동 제시(동향 근거)	–	○	–	–	△(유지보수 비용)
본 연구	○(홀론 실행 규칙 불변)	○(요인별 후보 + 사전 검증)	○(정보 동등·공정별 규칙)	○(SIL 롤백 조회)	○

Table 1 이 보이듯, 검토한 선행연구 범위에서는 기존 실행체계를 보존한 채 예측·설명·대응·사전 검증·실패 시 복구를 하나의 폐루프로 통합하고 동일 정보 규칙과 비교하여 생산 지표로 검증한 사례가 확인되지 않았다. 본 연구는 이 간극을 대상으로 한다.

3. 대상 시스템과 문제 정의

3.1 대상 무인공장의 구성

대상은 국내의 항공기 구조물 정밀가공 무인공장으로, 설비 구성과 운영 성과 수치는 운영사의 기술자료[32]에 근거하며 내부 생산 데이터는 사용하지 않았다. 설비 구성은 Table 2 와 같다. 부품은 황삭·황정삭·정삭의 3 개 오퍼레이션(각각 로딩·가공·세척·언로딩)을 거친 뒤 정도검사와 CMM 검사를 거쳐 출하된다. Fig. 1 은 이 공장의 4 계층 구조와 진화 과정을 보인다. 엔터프라이즈 계층은 ERP 로부터 확정 수주의 품목·납기·수량만을 받고, 자율 계획 계층의 APS 엔진이 병목 설비 기준 전개로 생산계획·작업오더·NC 프로그램·공구·팔레트·검사·출하 지시를 자율 생성한다. 홀로닉 실행 계층에서는 설비마다 Dispatcher·Driver·Schedule 프로세스가 독립적으로 이송 요청·가공 대기·재할당을 규칙 기반으로 협상하고, 장애 설비는 스스로 협업 불가를 선언하고 라인에서 분리된다. 우선순위는 긴급, 납기 일시, 순번의 순서이며, 저순위 작업을 중단하고 고순위 제품을 이동시키는 동적 선점형 재스케줄링을 2017 년부터 운영해 왔다.

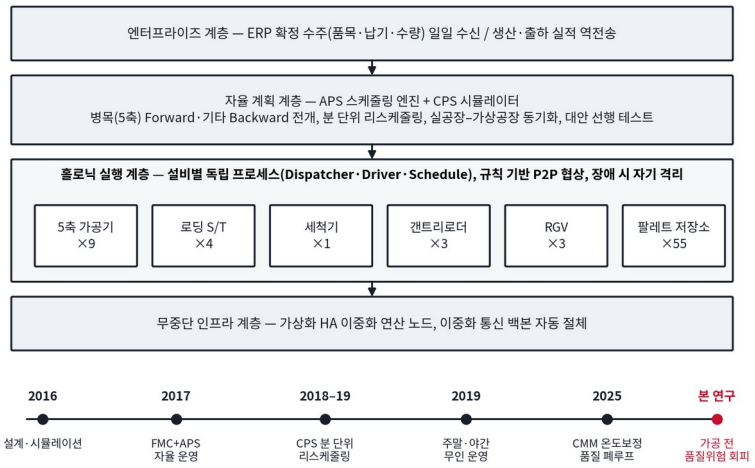


Fig. 1. 대상 무인공장의 4 계층 구조와 자율화 진화 과정. 본 연구는 자율 계획 계층과 홀로닉 실행 계층 사이에 가공 전 품질 판단을 더한다.

Table 2. 대상 무인공장의 설비·운영 사양 요약

항목	내용
제어 대상 설비	외산 5 축 정밀 가공기 9 대, 세척기 1 대, 로딩스테이션 4 대, 갠트리로더 3 대, RGV 3 대, 팔레트 저장소 55 개
공정 구성	3 오퍼레이션(황삭·황정삭·정삭) × 4 단위공정(로딩·가공·세척·언로딩) = 12 단위공정 + 정도검사·CMM 검사
상위 시스템 연동	ERP 확정 수주(품목·납기·수량) 일일 자동 수신, 생산·출하 실적 자동 역전송
자율 생성 범위	생산계획, 작업오더, 우선순위, NC 프로그램, 공구·팔레트, 자재 투입, 로트 추적, 검사·출하 지시, 수리 요청, 예방정비 시점
제어 구조	APS 중앙 계획 + 홀로닉 분산 실행(설비별 Dispatcher/Driver/Schedule), CPS 분 단위 리스케줄링, 동적 선점형 재스케줄링
우선순위 정책	긴급 › 납기 일시 › 순번; 설비 장애 시 자기 격리 후 작업 자동 재할당
품질 폐루프(기존)	CMM 측정 → 온도 보정 분석 → 가공 스케일 도출 → 가공기 자동 적용(2025)
운영 조직	생산·생산관리 부서 없음; 주말·야간 정비 인력 없이 무인 가동(2019~)
운영 성과(기술자료 기준)	순가동률 87.0% → 93.7% (규칙 기반 운영 대비 선점형 재스케줄링·CPS 고도화 후)

2019 년의 CPS 고도화에서는 실공장과 가상공장을 분 단위로 동기화하여 설비 일시정지·통신 오류·셋업 지연에도 같은 시각 기준으로 재계획되도록 하였고, RGV 선행이동, NC 프로그램 조기 전송, 세척 순서 변경 등의 규칙이 시뮬레이터에서 먼저 검증된 뒤 적용되었다. 그 결과 순가동률은 87.0%에서 93.7%로 상승하였다(Table 2)[32]. 모든 계획과 제어는 사전 승인 없이 자율 생성·적용되지만, 담당자는 언제든 우선순위를 재조정하거나 특정 설비의 사용을 지정할 수 있는 하이브리드 오버라이드가 유지된다.

3.2 기존 품질 폐루프와 그 한계

대상 공장은 2025 년에 CMM 측정 데이터를 자동 수집·분석하여 온도 영향을 보정하고, 도출된 가공 스케일을 가공기에 자동 반영하는 품질 폐루프를 완성하였다(Fig. 2(a)). 이는 "검사는 공정의 끝이 아니라 다음 가공을 더 정확하게 만드는 입력"이라는 원칙을 구현한 것으로, 측정실과 가공장의 온도 차이에 따른 오판정과 수작업 보정을 제거하였다. 그러나 이 루프는 두 가지 구조적 한계를 갖는다. 첫째, 루프가 측정 이후에 닫히므로 편차를 만든 부품은 이미 가공되어 재작업 또는

폐기 대상이 된다. 둘째, 보정 대상이 온도에 의한 계통 편차이므로 공구 마모, 설비 상태 변화, 셋업 불량처럼 부품마다 다르게 나타나는 원인은 다루지 못한다. 설비 상태 데이터 기반 예방정비 시점 제안 기능이 별도로 존재하지만, 이는 " 설비를 언제 정비할 것인가"에 답할 뿐 "다음 부품의 품질이 위험한가"에는 답하지 않는다.

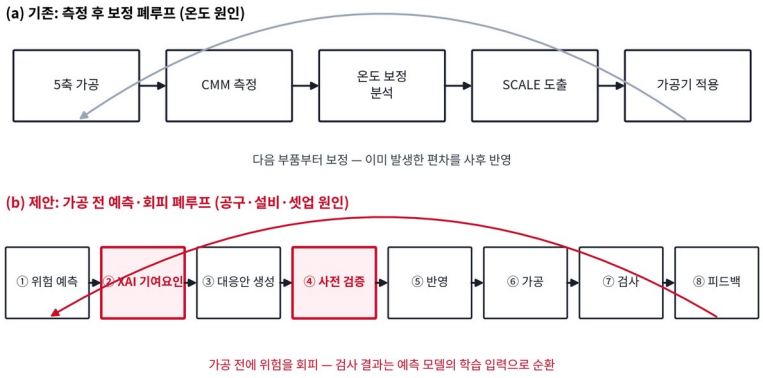


Fig. 2. (a) 기존의 측정 후 보정 폐루프와 (b) 제안하는 가공 전 예측·회피 폐루프. 두 루프는 서로 다른 원인을 다루며 상보적으로 공존한다.

본 연구가 제안하는 가공 전 예측·회피 폐루프(Fig. 2(b))는 기존 루프를 대체하지 않는다. 온도에 의한 계통 편차는 기존 루프가, 공구·설비·셋업에 의한 부품별 위험은 새 루프가 담당하며, 두 루프는 같은 CMM 데이터를 공유한다.

3.3 문제 정의

부품 j 의 오퍼레이션 k 를 설비 m 에서 가공하기 직전 시점 t 를 예측 시점으로 정의한다. 이 시점에 이용 가능한 정보는 가공 조건 c(이송률, 클램프 압력 등 NC 프로그램과 셋업에서 알 수 있는 값), 설비 m 에 장착된 공구의 상태 w(누적 사용량에서 유도되는 마모 진행도), 설비 m 의 최근 상태 s(직전 가공 구간에서 수집된 축·스핀들 신호의 통계량)이며, 현재 구간의 신호는 아직 존재하지 않는다. 품질위험 예측기는 이 정보로부터 해당 부품이 검사에서 불합격하거나 가공이 안전상 중단될 확률 p 를 출력한다.

$$p = f(c, w, s) \quad (1)$$

p 가 임계값 τ 이상이면 대응안 집합 A = {공구 교체, 설비 재할당, 셋업 재확인, 유지} 중 하나를 선택한다. 선택 기준은 대응 후 예상 위험 p_a, 대응이 유발하는 지연 d_a와 납기 여유 σ_j, 공구 소모 여부 δ_a를 결합한 비용의 최소화이다.

$$a^* = \mathrm{argmin}_a \{ w_q \cdot p_a + w_d \cdot d_a / \sigma_j + w_t \cdot \delta_a \} \quad (2)$$

식 (2)는 단일 부품 관점의 개념적 목적함수이며, 6 장의 선행 시뮬레이션 구현이 실제로 최소화하는 집계 비용은 4.5 절의 식 (2′)에 정의한다.

연구 목표는 이 결정을 기존 홀로닉 실행 규칙 위에 얹었을 때, 같은 오더 세트에 대해 품질 이상률과 재작업률을 낮추면서 납기준수율과 순가동률을 유지하고, 공구 소모를 고정 임계 규칙 이상으로 늘리지 않는 것이다.

4. 제안 시스템: 품질위험 회피 폐루프

4.1 전체 구조와 안전 원칙

Fig. 3 은 제안 시스템의 구조이다. 지능 계층은 자율 계획 계층(APS+CPS)과 홀로닉 실행 계층 사이에 위치하며 품질위험 예측기, XAI 위험 기여요인 설명, 대응안 생성기, 사전 검증기의 네 모듈로 구성된다. 설계의 안전 원칙은 세 가지이다. 첫째, 지능 계층은 프로그래머블 로직 컨트롤러(PLC)나 수치제어기(CNC)를 직접 제어하지 않으며 대응안을 제안할 뿐이다. 둘째, 제안된 대응안은 CPS 시뮬레이터의 대안 선행 테스트와 같은 원리의 사전 검증을 거친 뒤에만 실행 계층에 전달된다. 셋째, 검증된 대응안은 기존 홀론의 규칙으로 실행되며, 담당자의 하이브리드 오버라이드는 그대로 유지된다. 이 원칙은 "모든 규칙 변경은 시뮬레이터에서 먼저 검증한 뒤 현장에 적용한다"는 대상 공장의 기존 운용 문화를 AI 의 판단에까지 연장한 것이다.

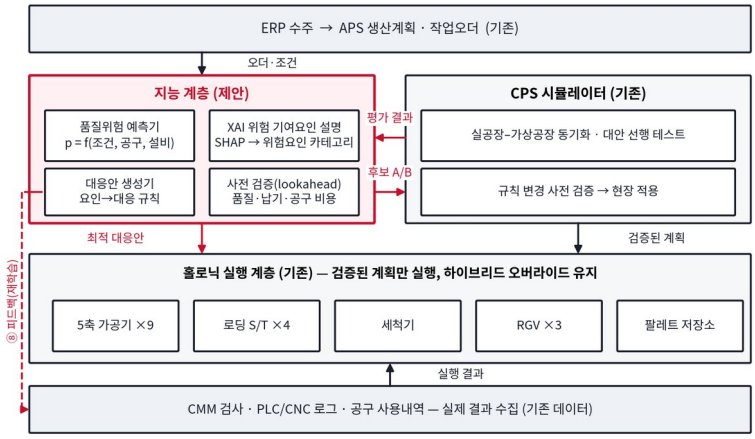


Fig. 3. 제안 시스템 구조. 지능 계층(붉은 테두리)은 기존 APS–CPS–홀론 구조를 대체하지 않고 그 사이에서 예측·설명·대안을 공급한다.

4.2 8 단계 페루프

Fig. 4 는 지능 계층이 닫는 8 단계 페루프이다. ① 가공 직전에 식 (1)로 위험 확률을 계산하고, ② XAI 가 위험을 높인 요인을 공구 수명, 운영 조건, 설비 상태의 세 카테고리로 귀속하며, ③ 위험요인 카테고리별 대응 규칙으로 후보를 생성한다. ④ 후보마다 예상 위험·지연·공구 소모를 식 (2)로 평가하여 최적안을 고르고, ⑤ 이를 APS 와 홀론 스케줄에 반영한다. ⑥ 기존 홀론이 가공을 실행하고 ⑦ CMM 검사가 결과를 내며, ⑧ 검사 결과가 예측기의 학습 데이터로 축적되어 일정 건수마다 예측기를 재학습한다. 이 중 ①–④와 ⑧은 본 연구가 추가한 지능 계층의 기능이며, ⑤–⑦ 은 기존 APS·홀론 실행·CMM 검사 기능과 연계한다. 나머지 단계는 기존 시스템의 기능(APS, 홀론 실행, CMM 데이터 관리, 이벤트 로그)과 연결된다.

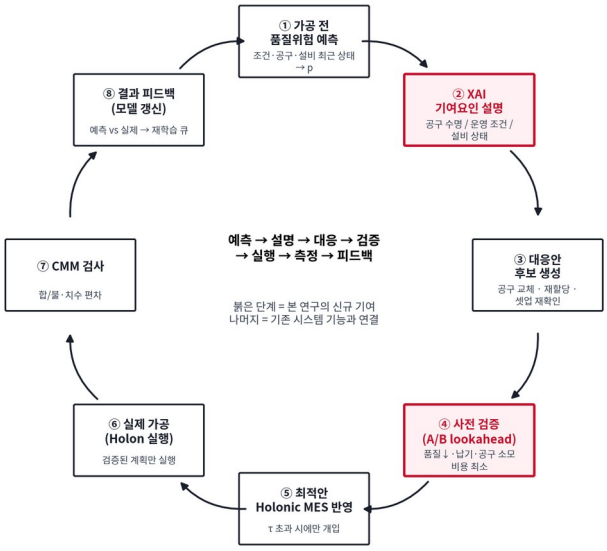


Fig. 4. 예측–설명–대응–검증–실행–측정–피드백의 8 단계 페루프.

4.3 품질위험 예측기

예측기의 입력은 3.3 절의 세 정보군이다. 가공 조건군은 이송률과 클램프 압력, 공구 상태군은 공구 마모 여부(공개 데이터의 이진 라벨)와 해당 공구의 누적 가공시간, 설비 최근 상태군은 직전 가공 구간의 스핀들 출력 표준편차, 스핀들 전류 실효값, 이송축 전류 최댓값, 이송축 위치 추종오차 실효값이다. 설비 최근 상태군은 후보 60 여 개 중 5 개로 축소하였는데, 5 장에서 보이듯 표본 규모에서는 축소 집합이 전체 집합보다 일반화 성능이 높기 때문이다. 모델은 로지스틱 회귀를 기본으로 하고 랜덤 포레스트와 XGBoost[28]를 비교한다. 평가는 반드시 실험(부품) 단위로 학습·검증을 분리하는 Leave-One-Experiment-Out 교차검증으로 수행하며, 이는 같은 부품의 여러 가공 구간이 같은 라벨을 공유하는 상황에서 무작위 분할이 초래하는 정보 누출을 막기 위함이다. 항공 품질 관점에서는 실제 위험을 정상으로 놓치는 미탐(false negative)이 오탐보다 훨씬 비싸므로, τ 는 재현율을 우선하여 낮게 설정하고 오탐의 비용(불필요한 대응이 유발하는 납기 영향)은 ④단계의 사전 검증이 걸러내도록 역할을 분담한다.

4.4 XAI 위험 기여요인 설명과 대응안 생성

예측기가 τ 를 넘는 위험을 출력하면 SHAP[15] 등으로 각 입력 변수의 기여도를 계산하고, 변수를 Table 3 의 위험요인 카테고리로 묶어 부호 있는 기여도 합을 구한다. 이 구조는 세 층위로 구현·검증된다. 5 장은 공개 데이터의 11 피처 모델에 대한 out-of-fold SHAP 으로 설명의 방향성을 검증하고, 6 장의 시뮬레이션은 합성 로지스틱 예측기의 계수 기여항(마모 계수×마모 상태, 셋업 계수×관측 셋업 상태)으로 두 카테고리의 기여를 계산하는 단순화 구현을 쓴다(6.1 절). 따라서 시뮬레이션 결과는 SHAP 자체의 성능 효과가 아니라 "기여요인에 따른 후보 정리와 사전 검증" 구조의 효과로 읽어야 한다. 각 카테고리는 대상 공장에서 실제로 취할 수 있는 대응과 일대일로 연결된다. 공구 수명 카테고리는 선행 공구 교체로, 운영 조건 카테고리 가운데 가공 전에 조치할 수 있는 셋업 상태(클램프 압력)는 셋업 재확인(재클램핑)으로, 설비 상태 카테고리는 다른 가공기로의 재할당으로 대응한다. 5 장의 검증에서 위험 사례의 상당수가 공구 마모와 가공 조건이 결합된 복합 원인이었으므로, 대응안 생성기는 기여도 합이 가장 큰 카테고리 하나만이 아니라 상위 두 카테고리의 대응을 모두 후보로 생성하여 ④단계에 넘긴다. 변수는 조치 가능 변수와 문맥 변수로 구분한다(Table 3). NC 프로그램에 고정된 이송률·공정 단계는 예측·설명에는 쓰이지만 자동 대응은 생성하지 않고 담당자 검토 항목으로만 제시한다. 또한 설명이 모호할 때의 안전장치를 둔다. 상위 두 카테고리의 기여도(로짓 단위 부호 있는 합) S_1, S_2에 대해 $|S_1 - S_2| < \varepsilon$ 이면 후보를 가지치기하지 않고 ④단계가 모든 대응안을 평가하며, 본 연구는 ε=0.5(승산비 약 1.6 배에 해당)를 사용하고 6.6 절에서 ε=0~2 및 항상 전수 평가에 대한 민감도를 확인한다. 이 규칙은 설명 오류의 영향을 전달된 후보 안에서 완화하는 것이며, 최적 후보의 포함이나 올바른 선택을 보장하지는 않는다(6.5 절의 반사실 평가에서 후보 선택은 전체 공장 평가와 약 3 분의 1 에서 어긋났다). 이렇게 하면 XAI 는 위험요인에 따라 후보를 정리하고 각 대응안의 판단 근거를 제공하는 모듈로 기능한다. 후보 수가 적은 설정에서는 ④단계가 모든 후보를 평가해 같은 결정에 이를 수 있으며(6.6 절), 그 경우 ②의 역할은 설명이다.

Table 3. XAI 위험요인 카테고리와 대응안 매핑 규칙 (조치 가능 변수와 문맥 변수의 구분)

위험요인 카테고리	귀속 변수	변수 성격	자동 대응안	비용 요소
공구 수명	공구 마모 여부, 누적 가공시간	조치 가능	선행 공구 교체	교체 시간, 공구 소모
운영 조건 — 셋업 상태	클램프 압력	조치 가능	셋업 재확인(재클램핑)	재클램핑·재로딩 시간
운영 조건 — 가공 조건	이송률, 공정 단계	문맥(예측·설명용)	자동 대응 없음, 담당자 검토 항목으로 제시	–
설비 상태	직전 구간 스핀들 부하(3), 이송축 추종오차(2)	조치 가능	다른 가공기로 재할당	이송·대기 지연

4.5 사전 검증(선행 시뮬레이션)과 실행

④ 단계의 사전 검증은 대상 공장의 CPS 가 규칙 변경안을 "적용 전에 먼저 돌려보는" 방식을 대응안 단위로 축소한 것이다. 결정 시점에 관련 설비의 상태(진행 중 작업의 잔여 시간, 대기 중 부품 목록, 관측된 공구 마모 진행도)를 스냅샷으로 뜬다. 각 후보에 대해 후보를 적용한 상태에서 해당 설비를 H 시간(기본 4 시간) 선행 실행하되, 설비 점유 시간과 임계 도달 시 교체 규칙은 운영 규칙 그대로 쓰고, 마모의 진행은 실현된 공구 수명이 아니라 평균 수명으로 예상하며, 각 후보 적용 후의 상태를 예측기에 입력하여 예상 위험을 산출한다. 지능 계층은 자신이 학습한 예측기만으로 후보를 평가하며, 환경의 실제 위험함수와 실현된 공구 수명은 지능 계층에 노출되지 않는다. 공구 교체 후보는 교체 시간을 더하고 마모를 0 으로 초기화한 뒤 진행하고, 재할당 후보는 가동 중이며 대기열이 짧은 설비 가운데 공구가 가장 새것인 설비로 대상 부품을 옮겨 원 설비와 대체 설비를 모두 선행 실행하며, 셋업 재확인 후보는 셋업 불량이 관측되었거나 설명이

모호할 때($|S_1 - S_2| < \varepsilon$, 4.4 절), 그리고 전수 평가 구성에서 생성되어 재클램핑 시간을 더한 뒤 진행한다. 여기서 셋업 상태는 로딩 시 측정되는 클램프 압력과 같이 가공 전에 관측 가능한 입력 변수이며, 그것이 품질에 미치는 영향의 크기는 예측기가 학습한 계수로만 반영된다. 유지 후보는 현재 상태 그대로 진행한다. 선행 실행의 결과로 창 안 정삭 검사의 기대 이상 수 F_a, 납기 초과 시간의 합 T_a, 공구 교체 수 N_a, 유지 대비 대상 부품의 추가 완료 지연 D_a를 얻고, 다음의 집계 비용을 최소화하는 후보를 고른다.

$$J(a) = w_q \cdot F_a + w_d \cdot T_a / \tilde{\sigma}_j + w_t \cdot N_a + 0.5 \cdot w_d \cdot D_a / \tilde{\sigma}_j \quad (2')$$

여기서 $\tilde{\sigma}_j$는 납기 여유 σ_j에 60 분 하한을 둔 값이고, 재할당 후보는 대체 설비를 후보 없이 선행 실행한 기존 부담을 차감하여 후보가 유발한 증분만 남긴다. 추가 지연항의 계수 0.5 는 납기 초과와 별도로 대상 부품의 완료 지연을 절반 가중으로 반영하기 위한 설정값이다. Table 6~8 에서 제안 정책의 대응안 선택에는 식 (2′)를 사용하였고, 6.5 절의 해석적 근사는 식 (2)를 사용하되 납기 여유에는 동일하게 60 분 하한을 적용하였다. 비용 가중치 w_q, w_d, w_t는 품질 이상 1 건, 납기 여유 전부의 소진, 공구 교체 1 회의 상대 비용을 뜻하며 본 연구에서는 각각 1, 1, 0.05 를 사용하였다. w_q=1, w_t=0.05 는 공구 교체 1 회의 비용을 품질 이상 1 건 비용의 0.05 배로 설정한 것으로, 항공 구조물에서 재작업 비용이 공구 비용을 크게 웃돈다는 판단을 반영한 값이며, 6.4 절에서 0~0.5 범위의 민감도를 검증한다. 본 구현(Python 3.11, SimPy, 2.1 GHz 급 서버용 x86 CPU 단일 코어)에서 선행 시뮬레이션의 계산시간은 결정당 0.12 ms(95 백분위)였으며, 소프트웨어 통합 환경에서의 종단간 지연은 6.7 절에서 별도로 평가하며, 실제 현장 PLC·DB·APS 를 포함한 종단간 지연은 후속 HIL/현장 검증 과제로 둔다. 선택된 대응안은 APS 의 작업오더와 설비 배정에 반영되고 이후의 실행은 기존 홀론 규칙에 따른다. 비교를 위해 후보별 기대 위험과 예상 지연을 현재 상태에서 직접 계산하는 해석적 근사도 구현하였으며, 두 방식의 차이는 6.5 절에서 검증한다.

4.6 검사 결과의 피드백 재학습

⑧ 단계는 정삭 후 검사 결과를 예측기의 학습 데이터로 되돌린다. 매 검사마다 (마모 진행도, 공차 엄격도, 셋업 상태, 합·불)이 버퍼에 축적되고, 40 건 이후 20 건마다 로지스틱 회귀를 재적합하여 예측기의 계수를 갱신한다. 초기 버퍼 40 건과 갱신 주기 20 건은 초기 학습 안정성과 적응 속도의 절충으로 정한 실험 설정이며, 6.6 절에서 버퍼 20~80 건, 주기 10~40 건에 대한 민감도를 확인한다. 검사는 정삭에서만 이루어져 공차 엄격도 계수는 식별되지 않으므로 사전값을 유지하고 절편만 정삭 기준으로 환산한다. 현장 배포에서는 재학습 뒤 최근 검사 버퍼로 확률 보정의 절편과 기울기를 별도로 갱신하여(5.3 절), 재학습만으로는 제거되지 않는 확률 과대·과신을 바로잡는다. 현장에서 예측기는 처음부터 정확할 수 없다. 공개 데이터로 학습한 모델이든 현장 데이터로 학습한 모델이든 설비 노후, 소재 로트, 계절에 따라 실제 위험 함수는 이동하므로, 피드백 재학습은 폐루프를 "닫는" 단계일 뿐 아니라 예측기의 오지정을 운영 중에 교정하는 안전장치이다. 6.5 절에서 예측기가 의도적으로 오지정된 상태에서 재학습이 성능을 회복시키는지 검증한다.

5. 데이터와 예측·설명 모델 검증

5.1 데이터와 라벨 정의

대상 공장의 개별 생산·품질 원시 데이터는 사용하지 않았으며(설비 구성과 운영 성과는 운영사의 미공개 기술자료를 참고), 예측기와 마모 모델은 공개 실측 데이터로 검증하였다. 주 데이터는 미시간대 SMART 연구실이 공개한 CNC 밀링 공구 마모 데이터[31]로, 18 회의 밀링 실험 각각에 대해 X·Y·Z 축과 스핀들 모터의 위치·속도·가속도·전류·전압·전력 등 48 개 제어기 신호가 100 ms 주기로 기록되어 있고, 실험 단위로 공구 상태(마모/정상), 가공 완료 여부, 육안검사 합격 여부가 라벨링되어 있다. 실험 조건은 이송률 3~20 mm/s, 클램프 압력 2.5~4.0 bar 이다. 보조 데이터는 NASA 밀링 마모 데이터[12](16 개 조건, 167 런, 플랭크 마모 VB)와 PHM 2010 데이터[11](공구 3 개, 각 315 회 절삭, 날별 마모량)로, 시뮬레이터의 공구 마모 상태식을 만드는 데 사용하였다. Table 4 는 대상 공장의 현장 변수와 공개 데이터 변수의 대응이다. 현장 적용 시에는 대응되는 현장 변수로 입력 스키마를 재구축하고, 현장 분포에 맞춘 재학습·재보정이 필요하다.

Table 4. 대상 공장 현장 변수와 공개 데이터 변수의 대응

논문 변수	대상 공장 현장 변수	공개 데이터 대체 변수	출처
품질 위험 Y	CMM 공차 이탈, 재작업	육안검사 불합격 또는 가공 중단	CNC Mill
가공 조건 c	NC 프로그램 가공조건, 셋업	이송률, 클램프 압력	CNC Mill
공구 상태 w	공구 사용내역 주기 수집	공구 마모 여부, 실험 내 누적 가공시간	CNC Mill
설비 최근 상태 s	PLC 데이터블록, Alarm/Mode	직전 구간 스핀들 부하·이송축 추종오차 통계량	CNC Mill

논문 변수	대상 공장 현장 변수	공개 데이터 대체 변수	출처
공구 마모 진행	(미측정)	절삭 횟수–마모량 곡선, 조건별 마모율	PHM 2010, NASA
온도·가공 스케일	CMM 온도보정 시스템	없음 (기존 폐루프 영역)	—

공개 데이터에는 CMM 공차 이탈 라벨이 없으므로, 검사 불합격 또는 정상 가공 완료에 실패한 사건을 품질·가공 이상 위험의 대리 라벨(proxy label)로 정의하였다. 가공 중단을 포함한 이유는 두 사건 모두 "부품을 다음 공정으로 넘길 수 없는 상태"라는 점에서 같고, 중단 사례가 셋업·조건 요인의 유일한 양성 표본이어서 요인 설명의 검증에 필요하기 때문이다. 검사 불합격 실험은 18 개 중 4 건이며, 이를 가공 구간 단위로 전개하면 양성 관측치는 24 개이고, 정상 가공 완료에 실패한(중단) 실험 4 건의 7 개 구간을 더해 양성이 31 개가 된다. 라벨을 검사 불합격만으로 좁히면 양성이 24 건으로 줄어 실험 단위 교차검증이 불안정해진다. 실험 단위의 결과 라벨을 그 실험의 모든 구간에 부여하므로, 구간의 양성 라벨은 그 구간에서 이상이 관측되었다는 뜻이 아니라 그 구간을 포함한 실험이 이상으로 끝났다는 대리 라벨이다. 공구 마모 여부는 라벨이 아니라 입력 변수로 두었는데, 그래야 XAI 가 "공구 마모 때문에 위험이 높아졌다"를 설명할 수 있기 때문이다. 관측 단위는 실험 내의 가공 구간(Layer 1~3 의 상·하행, 실험당 최대 6 개)으로 총 91 개이며 위험 31, 정상 60 이다. 가공 전 예측이라는 문제 정의에 맞추어, 각 구간의 설비 최근 상태 변수는 같은 실험의 직전 구간 신호에서 계산하였다. 여기서 "가공 전"은 부품 투입 전이 아니라 진행 중인 공정에서 다음 가공 구간(대상 공장에서는 다음 오퍼레이션)을 시작하기 직전을 뜻하며, 누적 가공시간과 직전 구간 신호는 그 시점에 이용 가능한 정보이다.

5.2 탐색적 분석

Fig. 5 는 18 개 실험의 조건과 품질 결과이다. 검사 불합격 4 건은 모두 마모 공구와 이송률 6 mm/s 이상, 클램프 4.0 bar 의 조합에서 발생하였고, 같은 마모 공구라도 이송률 3 mm/s 에서는 합격하였으며 정상 공구는 이송률 20 mm/s 에서도 합격하였다. 가공 중단 4 건은 공구 상태와 무관하게 낮은 클램프 압력 또는 높은 이송률에서 발생하였다. 즉 XAI 가 분리해야 할 두 위험요인 카테고리(공구 수명, 운영 조건)가 라벨 안에 실제로 섞여 있다. 신호 측면에서는 공구 마모의 흔적이 스핀들 출력보다 이송축 위치 추종오차에 뚜렷이 나타났는데, 이는 현장 적용 시 5 축 가공기의 PLC 데이터블록에서 축 추종오차를 수집해야 함을 시사한다.

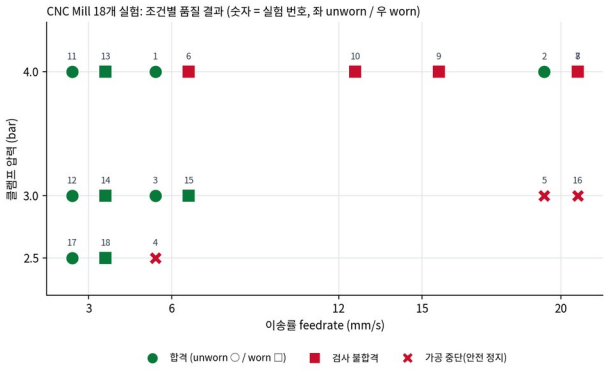


Fig. 5. 밀링 실험 18 건의 가공 조건과 품질 결과. 검사 불합격은 마모 공구와 높은 이송률의 결합에서, 가공 중단은 낮은 클램프 압력 또는 높은 이송률에서 발생하였다.

Fig. 6 은 시뮬레이터 마모 상태식의 근거이다. NASA 데이터에서 조건별 선형 마모율은 5.9~55.3 μm/min 으로 9 배 차이가 났고, 강이 주철보다 4~5 배, 이송 0.5 mm/rev 가 0.25 보다 1.3~1.7 배 빨랐다. PHM 데이터의 마모 곡선은 공구 수명 이론[20]이 기술하는 초기 급증, 안정, 가속의 3 단계를 보였으며, 플랭크 마모 한계[21] 120 μm 도달 절삭 수는 공구별로 148~241 회(평균 193, 변동계수 0.24)로 같은 조건에서도 편차가 컸다. 이 두 결과는 시뮬레이터에서 오퍼레이션별 마모율 배수(정삭 1.00, 황정삭 1.58, 황삭 2.09)와 공구 수명 분포를 정하는 데 사용되었다.

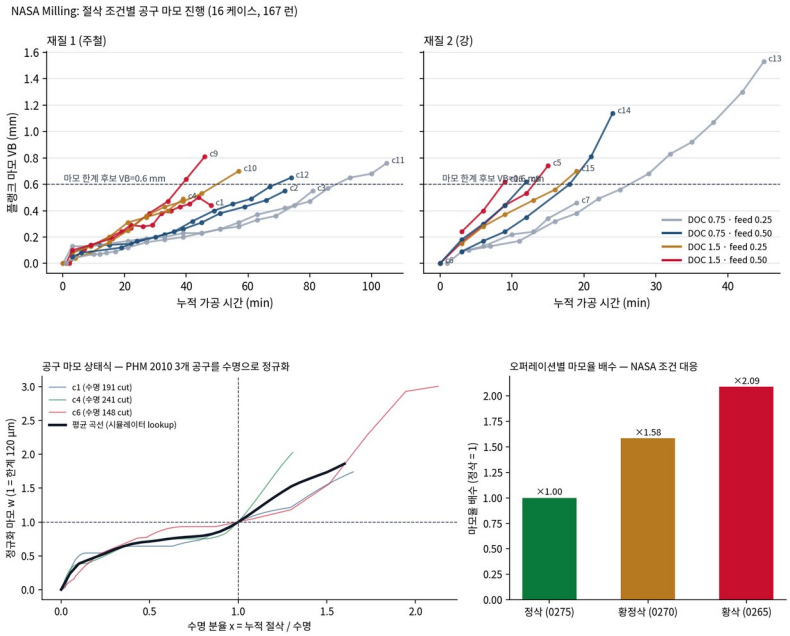


Fig. 6. (a) NASA 밀링 데이터의 조건별 공구 마모 진행. (b) PHM 2010 데이터로 정규화한 마모 상태식과 오퍼레이션별 마모율 배수.

5.3 예측 성능

Fig. 7(a)는 피처 집합별·모델별 AUC 이다. 가공 조건만으로는 0.81, 공구 상태를 더하면 0.85~0.87 이었고, 공정 단계와 누적 가공시간을 추가한 최고 조합의 AUC 는 0.89 였으며, 설비 신호 통계 5 개와 직전 구간 존재 여부를 추가한 조합에서는 0.81~0.88, 설비 신호 53 개를 전부 넣으면 0.77~0.81 로 나타났다. 표본 91 에서는 단순한 모델과 적은 피처가 일반화에 유리하였다. 모델·피처 집합은 실험 단위 교차검증 AUC 가 가장 높은 조합을 택하였고(로지스틱 회귀를 우선 후보로 두었으나 사전 고정은 아니었다), 같은 교차검증 결과로 여러 조합을 비교해 최고값을 보고하므로 낙관 편향이 남는 탐색적 결과이다. 선택된 조합은 로지스틱 회귀(조건+공구+누적시간, 피처 5 개)로 AUC 0.890, 불균형 자료에 적합한 평균정밀도[29] 0.827, Brier 점수 0.137, 실험 단위 부트스트랩(1,000 회) 95% 신뢰구간 0.72~0.99 였다. 구간은 같은 실험 안에서 독립이 아니므로, 실험별 평균 예측 확률로 18 개 실험을 평가한 실험 단위 AUC 는 0.788 로 더 낮으며 실험 단위 의사결정에는 이 집계 성능을 함께 고려해야 한다. Fig. 7(b)는 τ 에 따른 재현율과 정밀도로, τ=0.3 에서 재현율 0.97(위험 31 건 중 1 건 미탐), 정밀도 0.60 이며 τ=0.6 에서는 재현율 0.77, 정밀도 0.75 이다. 4.3 절의 역할 분담에 따라 본 연구는 낮은 τ 를 채택한다. 현장에서는 가공 전에 공구의 마모 여부를 이진 라벨로 알 수 없으므로, 마모 라벨을 제외하고 누적 가공시간과 설비 최근 상태만으로 학습한 모델도 검증하였다. 이 경우 AUC 는 0.832(95% 신뢰구간 0.63~0.98, 평균정밀도 0.618, Brier 0.169)로 0.89 보다 낮지만 가공 조건만의 0.81 보다 높았으며, 현장 적용 시에는 이 구성으로 재학습한다. 데이터 누출 점검에서 스핀들 출력 전류 최댓값이 특정 실험 배치(모두 위험 라벨인 6 건)에서만 328 A, 나머지에서 330 A 로 양자화되어 배치를 식별하는 인공물임을 발견하고 해당 계열 변수를 제외하였다(제외 전 AUC 0.90 은 라벨을 우회 학습한 결과). 이 점검 절차는 현장 데이터에도 적용되어야 한다.

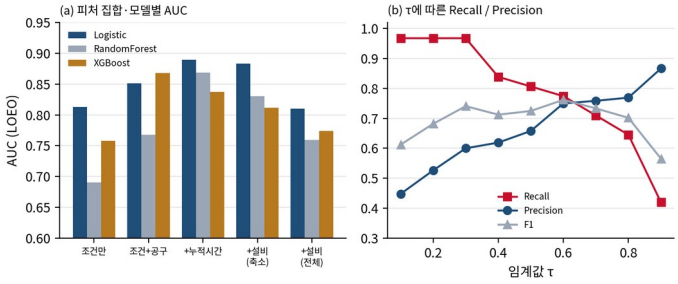


Fig. 7. 품질위험 예측 성능. (a) 피처 집합·모델별 AUC(실험 단위 교차검증), (b) 임계값 τ 에 따른 재현율·정밀도.

식 (2)는 예측 확률의 순위가 아니라 크기를 비용에 넣으므로 확률 보정(calibration)도 확인하였다. Fig. 8 은 두 모델의 out-of-fold 보정 곡선이다. 최고 모델은 보정 기울기 0.90 으로 순위 정보의 구분은 유지하나, 클래스 균형 가중치 때문에 예측 확률이 전반적으로 과대(평균 예측 0.44 대 실제 양성 비율 0.34, 절편 −0.81, ECE 0.095)하며, 현장형 모델은 기울기 0.44 로 높은 확률 구간에서 과신하는 경향을 보인다(ECE 0.097; 다만 n=91 에서 기울기 추정의 불확실성이 크므로 이 값 자체보다 재보정이 필요하다는 방향만 해석한다). 따라서 현장 배포에서는 예측기를 재학습한 뒤 별도의 로짓 절편·기울기 재보정을 수행하여 보정된 확률을 비용에 투입해야 한다. 모델 재학습과 확률 재보정은 같은 작업이 아니며, 클래스 균형 가중치를 그대로 두고 재학습하면 유병률에 따른 과대 추정이 남을 수 있으므로 4.6 절의 ⑧단계는 재학습과 재보정을 함께 수행하는 운영 피드백 단계로 확장한다. 6 장의 시뮬레이션에서는 예측기가 환경 위험함수와 같은 척도로 정의되므로 이 문제가 발생하지 않는다.

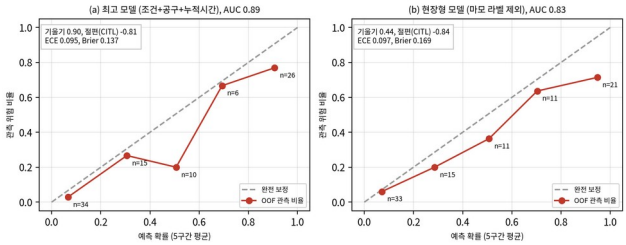
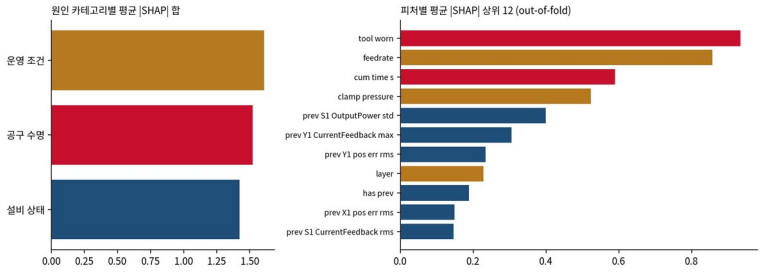


Fig. 8. 예측 확률의 out-of-fold 보정 곡선(5 구간). (a) 최고 모델, (b) 현장형 모델. 기울기·절편은 로짓 재보정 회귀, ECE 는 기대 보정 오차.

5.4 XAI 설명의 방향성 및 일관성 평가

설명에 쓴 모델은 5.3 절의 최고 성능 모델(피처 5 개)이 아니라, 설비 상태 카테고리를 대응안(재할당)에 연결하기 위해 기본 5 개 피처(이송률, 클램프 압력, 공구 마모 여부, 공정 단계, 누적 가공시간)에 직전 구간의 설비 신호 통계 5 개와 직전 구간 존재 여부를 추가한 로지스틱 회귀(총 11 개 피처, AUC 0.883)이다. 즉 5.3 절의 AUC 0.890 과 본 절의 설명은 다른 모델의 결과이며, 현장 적용에서는 두 모델을 하나로 통일한다. Fig. 9 는 out-of-fold SHAP 결과이다. 전역 중요도는 공구 마모 여부(0.93), 이송률(0.86), 누적 가공시간(0.59), 클램프 압력(0.52), 직전 구간 스핀들 출력 표준편차(0.40) 순이었고, 카테고리 합은 운영 조건 1.61, 공구 수명 1.52, 설비 상태 1.42 로 균형을 이루었다. 위험 구간 31 건에 대해 사전에 정의한 대리 원인 라벨(검사 불합격은 공구 수명, 가공 중단은 운영 조건)과 비교하면, 해당 라벨 카테고리의 SHAP 합이 위험을 올리는 방향(양수)이었던 비율은 공구 수명 100%, 운영 조건 86%였다. 기여도 합이 가장 큰 카테고리의 일치율은 세 기준으로 나누어 보고한다. (i) 모든 사례에 공구 수명·운영 조건 두 카테고리를 허용: 26/31(84%); (ii) 라벨별 허용 집합(불합격은 두 카테고리, 중단은 운영 조건만): 25/31(81%); (iii) 대리 원인 라벨과 단일 카테고리의 정확 일치: 13/31(42%, 공구와 이송률이 경합). (i)·(ii)는 설명이 주요 카테고리 밖으로 벗어나지 않는 비율이지 원인 규명 정확도가 아니며, 예측 상위 두 카테고리에 정답이 포함되는 비율과도 다르다. 이 결과가 4.4 절에서 상위 두 카테고리의 대응을 모두 후보로 생성하도록 설계한 근거이다. 이 대리 원인 카테고리는 인과적 정답이 아니며, 본 평가는 설명의 방향성과 데이터 정의 간 일관성 확인이다. 이진 마모 라벨을 제외한 현장형 구성(조건+누적시간+설비 상태)으로 같은 평가를 반복하면 방향 일치는 81%, 두 카테고리 허용 시 설명 일치율은 68%로 낮아졌는데, 공구 수명 카테고리가 누적 가공시간 하나에만 의존하기 때문이다. 현장 적용 시에는 누적 사용이력에 더해 마모 추정치 등 공구 상태 변수를 확보해야 함을 뜻한다. 국소 설명(Fig. 9 하단)에서는 마모 공구·고이송 사례에서 공구 상태와 이송률이, 저클램프 사례에서 클램프 압력이 위험을 올리는 방향으로 나타났으나, 저클램프 중단 사례(실험 4)는 out-of-fold 예측 확률이 0.03 으로 위험을 놓친 사례이기도 하여 방향이 맞는 설명이 곧 정확한 예측을 뜻하지는 않는다.



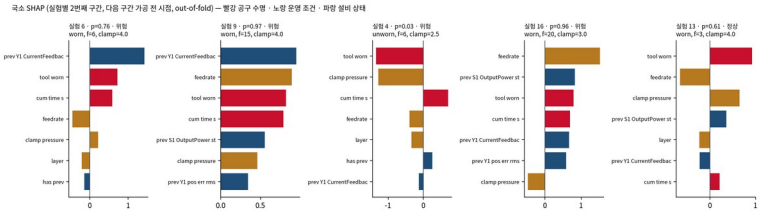


Fig. 9. XAI 결과. (상) 위험요인 카테고리별 및 변수별 전역 SHAP 중요도, (하) 대표 사례 5 건의 국소 설명. 빨강은 공구 수명, 노랑은 운영 조건, 파랑은 설비 상태 카테고리.

6. 시뮬레이션 기반 시스템 검증

5 장의 공개 데이터 검증은 가공 전 입력으로 위험을 예측·설명할 수 있는지를 평가한 것이고, 이 장의 시뮬레이션은 합성 위험 함수와 그에 맞춰 보정한 예측기로 정책·시스템 효과를 평가한다. 5 장의 모델이 그대로 공장을 제어한 것은 아니며, 실제 항공 가공 데이터의 예측기가 실제 정책 효과로 이어지는 종단 검증은 아직 없다(7.6 절).

6.1 시뮬레이터 구성

대상 공장의 설비 구성 사양(Table 2)에 따라 SimPy 기반 이산사건 시뮬레이터[22~24]를 구현하였다. 부품마다 황삭·황정삭·정삭의 각 오퍼레이션이 로딩스테이션, RGV 이송, 5 축 가공, RGV 이송, 세척, RGV 이송, 언로딩의 순서로 진행되며 정삭 후 검사가 이루어진다. 설비별 우선순위 자원(긴급, 납기, 순번)과 설비 선택 규칙(대기열 최소, 마모 최소), 설비 고장의 자기 격리, 대기 중 고장 감지 시 다른 설비로 재배치하는 선점형 재스케줄링, RGV 선행이동, NC 프로그램 조기 전송(중첩), 계획 시점 정적 배정과 실행 시점 동적 배정을 모두 스위치로 구현하여 3.1 절의 고도화 규칙을 켜고 끌 수 있게 하였다. 각 설비의 공구는 오퍼레이션마다 마모율 배수/수명만큼 마모 진행도 x 가 누적되고, 5.2 절의 정규화 곡선으로 마모 w 를 갱신한다. 검사 스텝은 정삭 후 w, 공차 엄격도, 셋업 불량 여부의 로지스틱 함수로 합·불을 판정하며, 불합격 부품은 정삭을 1 회 재작업한다. 기존 규칙은 마모 진행도가 임계에 도달하면 공구를 교체하는 정책이고(사후 교체 $x \geq 1.0$, 예방 교체 $x \geq 0.8$, 0.6), 제안 시스템은 4 장의 지능 계층(①~⑤, 선행 시뮬레이션 4 시간, 식 (2′))을 구현한 정책이며, ② 는 합성 예측기의 계수 기여항으로 마모·셋업 두 카테고리의 기여를 계산하고 공구 교체·재할당 후보는 항상, 셋업 재확인 후보는 관측 셋업 상태 또는 설명 모호성(4.4 절)에 따라 생성하는 단순화 구현이다. 주 실험의 예측기는 6.3 절대로 보정된 고정 예측기이며 ⑧단계의 재학습은 주 실험에 포함하지 않고 6.5 절에서 별도로 평가한다. 모든 정책에 동일하게, 공구 교체(규칙·선행·재작업 전 교체 모두)는 설비를 점유한 채 20 분이 소요되고 선행 교체는 설비 확보 시점에 공구가 이미 새것($x<0.05$)이면 실행하지 않는다. 정삭 검사는 그 부품을 가공했을 때의 공구·셋업 상태로 판정하며, 재작업한 부품은 재검사 없이 완료로 처리한다(가정). 설비 고장은 라인 단일 생성기가 이전 수리 완료 후 다음 고장까지의 대기시간을 평균 6.7 시간(설비별 파라미터 60 시간/9 대)의 지수분포로 생성하고 고장 설비는 무작위이며 동시 고장은 없다(설비별 MTBF 60 시간의 구현이 아니며 실현 빈도는 그보다 낮다). 선점형 재스케줄링은 대기 중인 작업만 재배치한다. 셋업 불량은 부품별 이진 상태로 생성되어 지능 계층과 정보 동등 규칙(6.3 절)에 관측되는데, 이는 클램프 압력 등으로 셋업 상태를 관측하는 것을 이상화한 가정이다. 모델링하지 않은 항목(이중화, 통신 절체, 3D 시각화, NC 파일 내용)은 정책 간 공통으로 보았다. Table 5 에 파라미터를 정리하였다.

Table 5. 시뮬레이터 주요 파라미터

항목	값	근거
설비	5 축 9, 로딩 S/T 4, 세척기 1, RGV 3, 팔레트 저장소 55	Table 2
가공 시간(분)	황삭 110, 황정삭 75, 정삭 55 (±5% 균일)	가정(일 50 부품 처리 수준)
로딩/언로딩/세척/RGV(분)	15 / 12 / 6 / 4	가정
설비 비절삭 시간(분)	팔레트 교환 2, NC 전송 3(중첩 시 0), 팔레트 도착 대기 4(선행이동 시 2)	2019 고도화 항목
공구	교체 20 분(모든 정책, 설비 점유 상태에서), 수명 38 오퍼레이션(정삭 기준, CV 0.24), 배수 황삭 2.09·황정삭 1.58·정삭 1.00	PHM 2010, NASA

항목	값	근거
설비 고장	라인 단일 생성기: 수리 완료 후 다음 고장까지 대기시간 지수분포 평균 6.7 h(고장 간격 파라미터 60 h/9 대), 고장 설비 무작위, 수리 3~10 h(균일), 수리 중 추가 고장 없음	가정(야간 무인)
수주	포아송 52/일(정상)·60/일(포화), 납기 여유 36~72 h, 긴급 8%	가정
품질 위험 생성	p = σ(a0 + a1·w + 1.0·공차엄격도 + 2.5·셋업불량), 고위험 a0=−6·a1=3.5, 저위험 a0=−7·a1=2.5; 셋업 불량률 6%(부품별 Bernoulli); 판정은 가공 시점의 w	5 장 예측기 형태
공차 엄격도	오퍼레이션 고정값: 황삭 0, 황정삭 1, 정삭 2 (정삭 검사에서만 이상 판정)	가정
초기 상태·워밍업	설비별 초기 공구 마모 U(0, 0.8), 워밍업 2 일(지표 제외) 후 5 일 측정, 종료 후 측정 기간 투입 부품 전부 완료까지 실행	6.3 절
AI 계층	$\tau \in \{0.3, 0.2, 0.1\}$, 가중치 w_q=1, w_d=1, w_t=0.05, 주 실험은 고정 예측기(재학습은 6.5 절)	4.5 절
반복	워밍업 2 일 + 측정 5 일 × 30 seeds, 공통 난수(오더·고장·부품 사건·공구 수명)	6.3 절

6.2 보정

시뮬레이터는 운영사 기술자료[32]의 운영 성과 지표에 대한 재현성을 기준으로 보정하였으며, 독립적인 현장 검증은 수행하지 않았다. 포화 부하(60 부품/일)에서 도입 전 규칙 세트(정적 배정, 비선점, NC 반출 후 전송, 선행이동 없음)와 고도화 규칙 세트(동적 배정, 선점형, NC 중첩, 선행이동)의 순가동률은 각각 87.3%와 94.4%로, 기술자료의 87.0%와 93.7%에 대해 +0.3%p 와 +0.7%p, 상승폭은 기술자료의 6.7%p 에 대해 7.1%p 였다(Fig. 10(a)). 언론에 보도된 같은 공장의 가공 부문 가동률 약 90%[37]도 두 규칙 세트의 재현값(87.3~94.4%) 범위 안에 있다. 가동률을 움직인 기제는 설비 점유 중의 비절삭 시간(팔레트 교환, NC 전송, 팔레트 도착 대기)으로 고도화 항목과 일대일로 대응하며, 처리량 16% 증가·납기준수율 32%p 상승·리드타임 2.8 시간 단축이 함께 나타나 기술자료의 서술과 방향이 일치하였다. Fig. 10(b)는 본실험에 앞선 예비 비교로, 제안 시스템의 곡선이 기존 규칙보다 아래에 놓이는 기제가 확인되어 6.3 절의 설계로 이어졌다

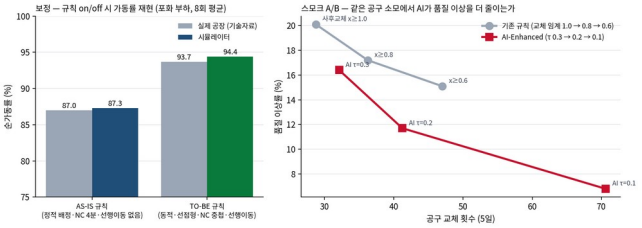


Fig. 10. (a) 규칙 세트 on/off 에 따른 순가동률의 재현(보정), (b) 예비 비교: 공구 교체 횟수 대비 품질 이상률(8 회 평균).

시뮬레이터의 공구 열화 모델(정규화 마모 곡선, 수명 분포, 오퍼레이션별 마모율 배수)은 5.1 절의 PHM 2010·NASA 실측 데이터로 파라미터를 정한 것이므로, 같은 데이터로 재현성을 말하면 순환 논증이 된다. 이를 피하기 위해 파라미터 추정에 쓰지 않은 실측 공구·실험에 대한 hold-out 검증을 수행하였다(Fig. 11). PHM 2010 의 공구 3 개에 대해 leave-one-cutter-out 으로 두 공구에서 곡선 형상과 평균 수명을 추정하고 나머지 한 공구의 궤적을 예측하면(공구당 177~289 점), 실제 수명을 알고 정규화한 형상만의 오차는 RMSE 7.6~11.8 μm, MAE 6.2~7.3 μm 로 한계 마모 120 μm 의 5~6%였고, 수명까지 다른 두 공구의 평균으로 대신하면 RMSE 7.1~21.5 μm, 한계 도달 절삭 수의 오차는 +2%, −29%, +46%였다. 즉 곡선 형상은 공구 간에 전이되지만 개별 공구의 수명은 예측되지 않으며, 이것이 시뮬레이터에서 수명을 변동계수 0.24 의 확률변수로 두고(6.1 절) 지능 계층이 실현된 수명이 아닌 평균 수명만 사용하도록 한 근거이다. NASA

데이터의 16 개 실험은 8 개 절삭 조건의 반복 2 군이므로, 한 군에서 소재별 기준 마모율과 오퍼레이션 배수를 추정해 다른 군의 마모율을 예측하는 교차 검증을 양방향으로 수행하였다(15 개 실험). 예측·실측 마모율의 Spearman 순위상관은 0.90(소재 내 0.71 과 0.39), 상대오차 중앙값 |31|%, VB 궤적 MAE 0.08 mm 였다. 황삭>정삭의 순서는 두 군 모두 유지되었으나 황삭·황정삭의 순서는 한 군에서 뒤바뀌어, 시뮬레이터의 오퍼레이션 배수(2.09, 1.58, 1.0)는 절대값보다 순서 정보만 신뢰할 수 있다. 이 오차 수준은 6.5 절의 강건성 격자(수명 변동계수 0.12~0.40)와 6.6 절의 예측기 오차 주입 실험이 다루는 범위 안에 있다.

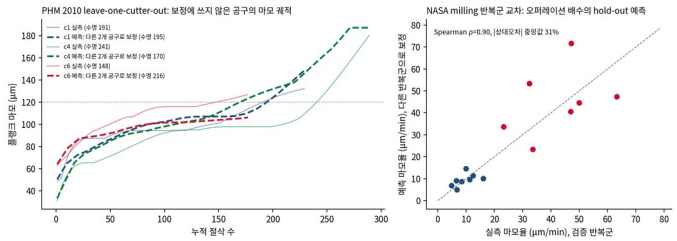


Fig. 11. 공구 열화 모델의 hold-out 검증. (a) PHM 2010 leave-one-cutter-out: 다른 두 공구로 보정한 모델이 예측한 마모 궤적(점선)과 실측(실선), (b) NASA milling 반복군 교차: 다른 반복군으로 추정한 오퍼레이션 배수로 예측한 마모율 대 실측(파랑: 주철, 빨강: 강).

6.3 실험 설계

짝지은 비교를 위해 공통 난수(common random numbers)를 적용하였다. 같은 시드는 같은 오더 세트를 생성하고, 부품 단위 사건(셋업 불량, 가공시간 변동, 검사 결과)은 (시드, 부품, 사건) 키, 공구 수명은 (시드, 설비, n 번째 공구) 키의 난수를 쓰므로 정책이 달라도 같은 부품·같은 공구는 같은 외생 난수를 받는다. 설비 고장은 독립 난수열의 시각 순서로 발생하여 정책에 따라 고장을 맞는 설비가 달라질 수 있으므로 완전히 동기화되지는 않는다. τ 의 선정에는 평가와 다른 시드(100~109)를 썼다(6.4 절). 본실험의 예측기는 계수가 환경의 위험함수와 일치하는 보정된 예측기를 가정한다(마모 관측과 수명 예상은 4.5 절대로 추정값 사용). 이는 폐루프의 효과를 예측 오차와 분리하기 위한 기준 실험이며(5 장 예측기의 입력 변수는 시뮬레이터 상태 변수와 대응하지 않아 그대로 쓰지 않았다), 계수 오지정·형태 불일치·관측 오차는 6.5·6.6 절에서 단계적으로 도입한다. 조건은 부하 2 수준(정상 52 부품/일, 포화 60 부품/일)과 품질위험 민감도 2 수준(고위험 a0=−6·a1=3.5, 저위험 a0=−7·a1=2.5)이며, 정책은 기존 규칙 3 종(사후 교체, 예방 교체 0.8, 0.6), 정보 동등 규칙 3 종, 제안 시스템 3 종(τ=0.3, 0.2, 0.1)으로 각 조건·정책마다 5 일 운영을 30 회 반복하였다. 정보 동등 규칙은 제안 시스템이 관측하는 셋업 불량 정보를 기존 규칙에도 똑같이 부여한 비교군으로, 셋업 불량이 관측되면 예측·설명·사전 검증 없이 항상 셋업 재확인을 수행하고 공구는 임계 규칙(x≥1.0, 0.8, 0.6)으로 교체한다. 이 비교군은 이득 가운데 "셋업 상태를 보고 재클램핑할 수 있다"는 정보·행동 조건에서 오는 부분과 예측·설명·사전 검증에서 오는 부분을 분리하기 위한 것이며, 기존 예방 교체 규칙은 대상 공장의 현재 운영 규칙에 해당한다. 각 실행은 설비별 공구 마모를 U(0, 0.8)로 무작위 초기화하고 앞 2 일을 워밍업으로 두어 지표에서 제외하며, 이후 5 일간 투입된 부품과 설비 시간만 집계한다(측정 종료 후 투입을 멈추고 투입된 부품이 모두 완료될 때까지 실행하여 미완료 부품이 분모에서 빠지지 않도록 하였다). 포화 부하 60 부품/일은 실제 수요 추정치가 아니라 고도화 규칙 세트의 처리 능력(약 55 부품/일)을 의도적으로 초과시키는 스트레스 시나리오이며, 절대 품질 이상률(10~20%)도 실제 공장 불량률 추정치가 아니라 정책 간 차이를 확대해 검증하기 위한 합성 스트레스 설정이다. 추가로 정상 부하·고위험·τ=0.2 에서 대응안 부분집합에 대한 절제 실험과 τ 0.05~0.5 의 민감도 실험을 수행하였다. 검증 단위는 공개 데이터 18 개 실험·91 개 구간, 조건별 30 개 시드의 짝지은 정책 실행(주 실험 1,500 회), 개발 시드와 평가 시드를 분리한 공정별 규칙 비교(640 회), SIL 의 정상 주기·장애 주입·드리프트 시퀀스이며, 보정·민감도·반사실 평가와 전체 공장 재실행을 합한 계산 작업 규모는 10,387 회이다(독립 실험 수가 아니며, 전 과정과 난수 시드는 재현 노트북으로 정리하였다). 이들 시뮬레이션에서 품질 이상률, 재작업률, 납기준수율, 순가동률, 리드타임(팔레트 확보 시점부터 완료까지), 공구 교체 수, 대응안 분포(평가·채택·실제 실행 횟수)를 수집하고 평균과 95% 신뢰구간을 보고하며, 정책 간 차이는 같은 시드끼리 짝지어 계산하였다.

6.4 결과

Table 6 은 정상 부하·고위험 조건의 종합 지표이다. 제안 시스템(τ=0.2)은 품질 이상률 11.5%로 사후 교체 규칙의 20.5%보다 44% 낮고, 예방 교체 규칙(x≥0.6, 14.6%)보다 21% 낮으면서 공구 교체도 47.1 회에서 41.0 회로 감소하였으며, 납기준수율 99.4%, 순가동률 93.6%로 예방 교체 규칙과 같았고 리드타임은 재작업 감소로 0.7 시간 단축되었다. 다만 순가동률은 사후 교체 규칙(94.2%)보다 0.6%p 낮은데, 공구 교체가 설비를 점유하므로 교체가 많은 정책일수록 절삭 시간 비율이 낮아지기 때문이다(예방 교체 규칙도 같다). 정보 동등 규칙(x≥0.6, 12.7%, 46.7 회)과

비교하면 제안 시스템은 이상률이 1.2%p(−9%) 낮고 공구 교체가 5.8 회(−12%) 적어, 셋업 정보를 같은 조건으로 부여한 규칙보다도 이상률과 공구 소모가 모두 낮았다. 정책 평균의 산술적 분해로 보면 예방 교체 대비 차이(−3.1%p) 가운데 정보 동등 규칙까지의 −1.9%p 는 "셋업 불량을 관측하고 재클램핑한다"는 정보·행동 조건에 대응하고, 나머지 −1.2%p 와 공구 절감이 예측·설명·사전 검증을 더했을 때의 추가분이다. 이는 구성요소별 인과적 기여율의 입증이 아니라 정책 간 평균 차이의 분해이다. Fig. 12 는 네 조건에서 공구 교체 횟수 대비 품질 이상률을 보인다. 고위험 두 조건에서 제안 시스템의 곡선은 기존 규칙의 곡선은 물론 정보 동등 규칙의 곡선보다도 아래에 있어, 같은 공구 교체 횟수로 보간하면 더 낮은 이상률에 대응한다(τ=0.2 의 공구 41 회에서 정보 동등 규칙의 보간값은 약 13.7%로 제안 시스템의 11.5%보다 높다). 포화·고위험에서도 예방 교체 대비 −2.3%p(−16%)의 이상률 감소와 함께 납기준수율이 1.9%p 높아졌고, 정보 동등 규칙 대비로는 −0.6%p(−4%, 유의한 차이를 확인하지 못함)에 공구 −5.6 회, 납기준수율 +1.1%p 였다. 마모가 위험을 크게 올리지 않는 두 저위험 조건에서 제안 시스템은 선행 공구 교체를 거의 하지 않아(τ=0.2 에서 5 일간 0.2~0.4 회) 공구 교체가 사후 교체 규칙과 같은 29 회에 머물고 이상률은 4.1~4.2%로, 기존 예방 교체(4.1~4.2%, 47 회) 대비 공구 18 회 감소·순가동률 +0.5%p 이지만 정보 동등 규칙의 x≥1.0(3.9%, 29 회)과 사실상 같은 운용점이며 정보 동등 규칙의 x≥0.6(2.6~2.8%, 47 회)보다는 이상률이 1.4~1.6%p 높다. 즉 저위험 조건에서는 셋업 정보를 쓰는 단순 규칙 대비 제안 시스템의 추가 개선을 확인하지 못했으며(평균이 비슷하다는 것이지 동등성을 검정한 것은 아니다), 예측·설명·사전 검증의 이득은 마모가 품질위험을 지배하는 고위험 조건에서 나타난다.

제안 시스템의 이득이 "정삭 전에만 더 일찍 교체한다"는 단순 규칙으로 설명되는지 확인하기 위해, 셋업 재클램핑에 황삭·황정삭·정삭별 교체 임계를 더한 공정별 규칙과 비교하였다(Table 8). 임계 격자 15 개 조합은 τ 선정에 쓴 개발 시드(100~109, 정상·고위험)에서 제안 시스템의 평균 공구 교체(43.6 회) 이내에서 이상률이 가장 낮은 조합(0.8/0.8/0.6)을 결과를 보기 전에 정한 기준으로 골랐고, 비교는 지금까지 어떤 선택에도 쓰지 않은 시드 200~229 에서 제안(τ=0.2 고정)·공정별 규칙·정보 동등·예방 교체를 함께 실행하였다. 새 시드에서 주 실험의 결과는 재현되었다(정보 동등 대비 −1.1%p, p=0.002; 예방 대비 −3.4%p). 그러나 공정별 규칙과 비교하면 정상·고위험에서 이상률 차이 +0.2%p(11.4% 대 11.2%)는 유의하지 않았고 공구는 제안이 1.1 회 적었으나 보정 후 유의하지 않았으며(Holm p=0.07), 포화·고위험에서는 공정별 규칙(11.1%)이 제안(12.1%)보다 이상률이 1.0%p 낮았다(Holm p=0.03). 즉 고위험 조건에서 조정된 공정별 규칙 대비 예측·설명·사전 검증의 추가 개선은 확인되지 않았고 포화 부하에서는 규칙이 우세하였다. 저위험 조건에서의 비교(Table 8 아래 두 행)에서는 규칙의 교체 임계와 제안의 τ·비용 가중치를 유지하되, 제안의 예측기는 저위험 위험 함수에 맞춘 계수로 초기화하였다. 규칙은 공구 42 회·이상률 2.7%의 운용점에 머문 반면 제안은 공구 29 회·4.2%(정보 동등 x≥1.0 과 같은 점)에 있었다. 이 결과는 조건별로 보정된 예측기를 쓸 때 τ·비용 가중치를 바꾸지 않고도 운용점이 달라짐을 보이는 것이지, 예측기 재조정 없는 이전이나 온라인 적응 성능을 입증하지 않으며, 어느 운용점이 유리한지는 재작업·공구 비용비에 달려 있다. 이 규칙은 재할당을 포함하지 않으므로 행동 조건이 완전히 같지는 않다.

Table 6. 정책별 종합 지표 (정상 부하·고위험, 30 회 평균, 품질 이상률은 평균 ± 95% 신뢰구간 반폭). 정보동등 규칙은 셋업 불량 관측 시 항상 셋업 재확인을 수행하는 규칙. 지능 계층 행은 측정 기간 안의 평가(p≥τ), 그중 유지가 아닌 대응을 채택한 횟수, 자원 확보 시 새 공구면 교체를 생략한 뒤 실제 실행된 횟수. 실제 실행의 공구 교체는 규칙 임계(x≥1.0) 도달에 따른 교체를 제외한 지능 계층의 선행 교체만 포함

지표	기존 사후 x≥1.0	기존 예방 x≥0.8	기존 예방 x≥0.6	정보동등 x≥1.0	정보동등 x≥0.6	제안 τ=0.3	제안 τ=0.2	제안 τ=0.1
품질 이상률	20.5 ±0.8	17.3 ±0.8	14.6 ±0.7	17.7 ±0.8	12.7 ±0.7	16.3 ±0.8	11.5 ±0.6	6.5 ±0.4
재작업률	20.5%	17.3%	14.6%	17.7%	12.7%	16.3%	11.5%	6.5%
납기준수율	99.2%	99.3%	99.3%	99.3%	99.4%	99.3%	99.4%	99.6%
순가동률	94.2%	93.9%	93.5%	94.1%	93.5%	94.0%	93.6%	92.7%
리드타임 (h, 팔레트 확보→완료)	22.7	22.4	22.2	22.4	22.0	22.1	21.5	21.7
공구 교체 (회/5 일)	28.8	35.8	47.1	28.9	46.7	32.0	41.0	70.5
지능 계층 평가 (회, p≥τ)	–	–	–	–	–	46	88	156
채택된 개입 (회)	–	–	–	–	–	37	75	136
실제 실행 (회)	–	–	–	–	–	31	71	130

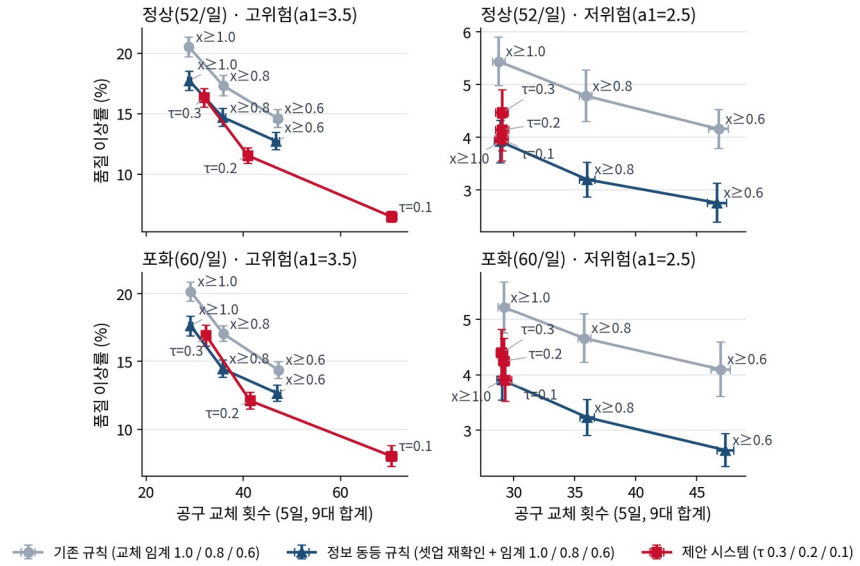


Fig. 12. 부하·위험 민감도 4 조건에서 공구 교체 횟수 대비 품질 이상률(30 회 평균, 오차막대 95% 신뢰구간). 고위험 두 조건에서 제안 시스템의 곡선은 기존 규칙과 정보 동등 규칙의 곡선 아래에 놓이고, 저위험 두 조건에서는 정보 동등 규칙의 사후 교체점과 겹친다. 단일 임계 규칙과의 비교이며, 조정된 공정별 규칙과의 비교는 Table 8 참조.

Fig. 13 의 짝지은 차이와 Table 7 의 검정 결과는 이 결과의 통계적 강건성을 보인다. 정상·고위험에서 제안 시스템(τ=0.2)은 예방 교체(x≥0.6) 대비 이상률 −3.1%p(95% 신뢰구간 −3.8~−2.4%p, Wilcoxon p<0.001, 효과크기 $|d_z|$=1.55), 공구 교체 −6.1 회(p<0.001), 순가동률 +0.1%p(p<0.001, 크기는 무시할 수준)였고, 포화·고위험에서는 이상률 −2.3%p(−2.9~−1.6%p, p<0.001, $|d_z|$=1.31), 납기준수율 +1.9%p(p<0.001), 순가동률 +0.2%p, 공구 교체 −5.9 회였다. 정보 동등 규칙(x≥0.6) 대비로는 정상·고위험에서 이상률 −1.2%p(−1.8~−0.6%p, p<0.001, Holm p=0.005, $|d_z|$=0.73)와 공구 −5.8 회(p<0.001), 포화·고위험에서 이상률 −0.6%p(−1.2~+0.1%p, 원 p=0.088, Holm p=0.26 으로 유의한 차이를 확인하지 못함)와 공구 −5.6 회(p<0.001), 납기준수율 +1.1%p(Holm p=0.030)였다. 즉 정보 동등 규칙 대비 이상률의 유의한 개선은 정상 부하·고위험 한 조건에서만 확인되었고, 포화 부하에서는 공구 절감과 납기 개선만 유의하였다. 예방·사후 교체 비교 32 개 검정(조건 4×기준 2×지표 4)에 Holm 보정을 적용해도 이상률·공구 교체의 유의 여부는 바뀌지 않았고, 사후 대비 납기준수율(정상·고위험)과 순가동률(정상·저위험) 2 건만 보정 후 유의하지 않게 되었다. 예방 교체 대비 8 개의 비교 어디에서도 납기준수율이나 순가동률이 유의하게 낮아진 경우는 없었으나, 사후 교체 대비로는 고위험 두 조건에서 순가동률이 0.5~0.6%p 유의하게 낮았다(교체 점유 시간의 차이). 예방 교체 대비 이상률 차이가 유의하지 않은 두 저위험 조건에 대해서는 "유의차 없음"을 "동등"으로 읽지 않도록 비열등성 검정을 추가하였다. 여유 한계 Δ 는 현장의 품질 허용 기준이 아니라 본 연구의 보수적 분석 기준으로, 기준(예방 교체) 이상률의 10%(약 0.4%p)로 사전에 두었다. 짝지은 차이의 단측 95% 신뢰상한은 정상·저위험 +0.23%p 로 Δ(0.42%p) 아래에 있어 비열등이 성립하였으나(단측 t p=0.003, 부트스트랩 10,000 회 상한 +0.22%p), 포화·저위험은 상한 +0.46%p 로 Δ(0.41%p)를 넘어 주 기준(10%)에서 실패하였고(p=0.08) 사후 민감도 기준 15%(0.62%p)와 절대 기준 1%p 에서만 성립하였다. 이 두 조건에서 공구 교체는 18 회 적었다. 반복 횟수의 충분성은 정상·고위험의 짝지은 차이가 반복 10 회 이후 −3.1~−3.2%p 로 안정되고 95% 신뢰구간 반폭이 5 회 1.6%p 에서 30 회 0.7%p 로 줄어드는 것으로 확인하였다.

Table 7. 제안 시스템(τ=0.2)과 예방 교체 규칙(x≥0.6)·정보 동등 규칙(x≥0.6)의 짝지은 검정 (30 쌍, Wilcoxon 부호순위 검정). Holm 보정은 예방 교체·사후 교체 비교 32 개, 정보 동등 비교 16 개를 각각 한 가족으로 적용(리드타임은 보정 대상 아님). d_z는 부호 있는 짝지은 효과크기(차이 = 제안 − 비교군). 본문·그림의 짝지은 평균 차이 95% 신뢰구간은 평균 차이 ± 1.96×표준오차의 정규근사이며 다중비교 보정은 적용하지 않았다(비열등성 분석의 단측 신뢰상한만 t 분포 사용)

조건	지표	차이 (제안−예방 0.6)	Wilcoxon p	Holm p	d_z	차이 (제안−정보동등 0.6)	Wilcoxon p	Holm p	d_z
정상·고위험	품질 이상률	-3.08 %p	<0.001	<0.001	-1.55	-1.20 %p	<0.001	0.005	-0.73
정상·고위험	납기준수율	+0.13 %p	0.069	0.618	+0.41	-0.01 %p	0.465	0.465	-0.07
정상·고위험	순가동률	+0.10 %p	<0.001	0.002	+0.35	+0.12 %p	<0.001	0.001	+0.70

조건	지표	차이 (제안−예방 0.6)	Wilcoxon p	Holm p	d_z	차이 (제안−정보동등 0.6)	Wilcoxon p	Holm p	d_z
정상·고위험	공구 교체	-6.10 회	<0.001	<0.001	-2.77	-5.77 회	<0.001	<0.001	-2.37
정상·저위험	품질 이상률	-0.02 %p	0.898	1.000	-0.03	+1.38 %p	<0.001	<0.001	+1.49
정상·저위험	납기준수율	+0.06 %p	0.138	0.966	+0.26	-0.05 %p	0.109	0.263	-0.31
정상·저위험	순가동률	+0.50 %p	<0.001	<0.001	+2.69	+0.51 %p	<0.001	<0.001	+3.17
정상·저위험	공구 교체	-17.70 회	<0.001	<0.001	-7.48	-17.57 회	<0.001	<0.001	-8.66
포화·고위험	품질 이상률	-2.26 %p	<0.001	<0.001	-1.31	-0.55 %p	0.088	0.263	-0.31
포화·고위험	납기준수율	+1.92 %p	<0.001	0.006	+0.80	+1.05 %p	0.007	0.030	+0.51
포화·고위험	순가동률	+0.15 %p	<0.001	<0.001	+1.27	+0.15 %p	<0.001	<0.001	+1.39
포화·고위험	공구 교체	-5.87 회	<0.001	<0.001	-2.21	-5.63 회	<0.001	<0.001	-2.23
포화·저위험	품질 이상률	+0.15 %p	0.191	1.000	+0.15	+1.62 %p	<0.001	<0.001	+2.13
포화·저위험	납기준수율	+1.36 %p	<0.001	0.011	+0.73	+0.94 %p	0.003	0.013	+0.60
포화·저위험	순가동률	+0.54 %p	<0.001	<0.001	+6.47	+0.57 %p	<0.001	<0.001	+5.07
포화·저위험	공구 교체	-17.70 회	<0.001	<0.001	-7.06	-18.10 회	<0.001	<0.001	-7.89

Table 8. 개발 시드에서 조정한 공정별 임계 규칙(셋업 재클램핑 + 황삭/황정삭/정삭 교체 임계 0.8/0.8/0.6)과 제안 시스템의 비교 (임계는 시드 100~109·정상·고위험에서 제안의 공구 예산 이내 최저 이상률 조합, 비교는 미사용 시드 200~229; Holm 보정은 고위험 2 조건×3 지표=6 개 가족). * 저위험 행: 규칙 임계와 제안의 τ·비용 가중치는 유지, 제안 예측기는 저위험 함수에 맞춰 초기화

조건 (평가 시드 200~229, 30 쌍)	제안 τ=0.2 이상률 / 공구	공정별 규칙 이상률 / 공구	정보동등 x≥0.6 이상률 / 공구	제안 − 공정별 규칙 이상률 (Holm p)	공구 (Holm p)
정상(52/일) · 고위험	11.4% / 41.0	11.2% / 42.2	12.5% / 47.4	+0.20 %p (1.000)	−1.1 회 (0.073)
포화(60/일) · 고위험	12.1% / 41.3	11.1% / 42.1	12.2% / 48.1	+1.04 %p (0.032)	−0.8 회 (0.359)
정상(52/일) · 저위험*	4.2% / 28.9	2.7% / 42.4	2.6% / 47.7	(검정 가족 외)	
포화(60/일) · 저위험*	3.8% / 29.3	2.7% / 42.4	2.7% / 47.8	(검정 가족 외)	

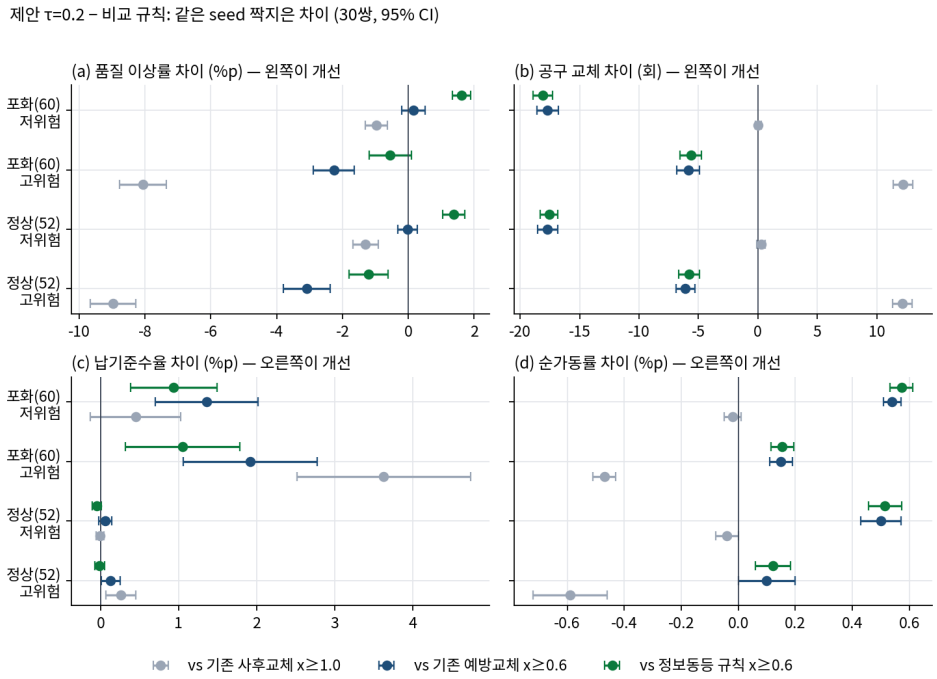


Fig. 13. 같은 오더 세트에 대한 제안 시스템(τ=0.2)과 세 비교 규칙의 짝지은 차이(30 쌍, 95% 신뢰구간). 품질 이상률과 공구 교체는 0 의 왼쪽이 개선, 납기준수율과 순가동률은 오른쪽이 개선이다. 단일 임계 규칙과의 비교(공정별 규칙은 Table 8).

Fig. 14 의 절제 실험은 어떤 대응이 효과를 내는지 분리한다. 공구 교체만 허용하면 이상률 12.0%에 공구 48 회, 셋업 재확인만 허용하면 공구 소모 없이 17.4%(사후 교체 20.5% 대비 −15%), 재할당만 허용하면 18.4%(−10%)였다. 세 대응을 요인별로 조합하면 11.5%에 공구 41 회로, 공구 교체만 쓸 때보다 이상률이 낮으면서 공구를 7 회 절약하였다. 재할당은 단독으로는 효과가 작지만 조합에서는 채택된 개입의 31%(5 일 평균 75.3 건 중 23.3 건; 평가 87.7 건 기준 27%)를 차지하는데, 선행 시뮬레이션이 대기열이 짧고 공구가 새것에 가까운 설비를 찾을 때만 선택되기 때문이다. τ 민감도에서는 τ 를 0.5 에서 0.05 로 낮추면 이상률이 18.0%에서 5.8%로 감소하는 반면 공구 교체는 29 회에서 85 회로 비선형적으로 급증하였고, 납기준수율은 τ 와 무관하게 ±0.3%p 안에 머물렀으며 순가동률은 교체 점유 시간 때문에 94.1%에서 92.2%로 낮아졌다. τ=0.2 의 선정은 평가 시드와 분리한 보정 시드(100~109)의 τ 스윕으로 하였다. 보정 시드에서 이상률 1%p 를 더 낮추는 데 필요한 추가 공구 교체는 τ 0.3→0.25 에서 0.1 회, 0.2→0.15 에서 4.8 회, 0.1→0.05 에서 45 회로 τ 가 낮아질수록 커지며, 공구 대 재작업 상대 비용 C_t/C_r로 총비용을 최소화하는 τ 는 $C_t/C_r \le 0.4$ 에서 0.1, 0.6~0.8 에서 0.2, 1.0 이상에서 0.25 였다. 본 연구는 공구 소모가 적은 쪽의 보수적 운용점 τ=0.2 를 대표로 채택하고 τ 0.05~0.5 전체를 보고하였다. 비용 가중치 w_d를 0.25~4, w_t를 0~0.1 로 바꾸어도 이상률 11.0~11.7%, 공구 38.9~42.4 회로 모두 예방 교체 규칙(14.6%, 47.1 회)보다 낮았고, w_t를 0.2·0.5 로 크게 하면 공구 33.6·30.9 회에 이상률 13.6·15.6%로 옮겨가지만 같은 공구 횟수의 기존 규칙(17.3%/35.8 회, 20.5%/28.8 회)보다는 낮아, w_t는 τ 와 마찬가지로 곡선 위의 운용점을 옮길 뿐 곡선의 우위를 바꾸지 않았다.

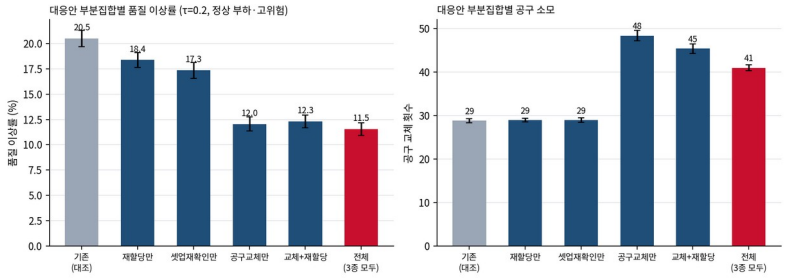


Fig. 14. 대응안 부분집합별 절제 실험(정상 부하·고위험, τ=0.2). 요인별 대응의 조합이 공구 교체 단독보다 낮은 이상률을 더 적은 공구로 달성한다.

6.5 부가 검증: 사전 검증 방식, 피드백 재학습, 강건성

④ 단계의 구현 방식을 비교하면, 해석적 근사와 선행 시뮬레이션(2·4·8 시간)은 이상률 11.3~11.5%, 공구 교체 40~41 회로 신뢰구간 안에서 겹쳤고 모두 예방 교체 규칙(14.6%, 47 회)보다 나았다. 본 구현 환경(Python 3.11, SimPy, 2.1 GHz 급 x86 단일 코어)에서 선행 시뮬레이션의 결정당 연산시간은 95 백분위 0.12 ms 였다(I/O 제외). 에뮬레이터 간 통합 지연은 6.7 절에서 평가하였다. 선행 시간을 늘려도 이득이 없는 것은 대응의 효과가 대상 부품과 그 직후 몇 건의 정삭에 국한되기 때문이며, 이는 현장 CPS 에 대응안 주입 인터페이스를 붙일 때 짧은 선행 창으로 충분함을 시사한다.

축약 선행 시뮬레이션이 설비 대기열과 공구 상태만 보고 RGV·세척 등 물류 자원을 생략한다는 점이 결정을 왜곡하는지는 전체 공장 반사실 평가로 확인하였다. 정상 부하·고위험 10 개 시드에서 개입 결정 지점 120 건을 무작위로 뽑아 각 후보 대응을 강제 적용한 전체 공장 시뮬레이션(물류·고장 포함, 공통 난수)을 후보마다 다시 실행하고(414 회), 결정 이후 4 시간 창의 공장 전체 비용(기대 이상 수 + 납기 초과/여유 + 0.05×공구 교체)을 비교하였다. 축약 선행 시뮬레이션이 고른 대응이 전체 공장 4 시간 반사실 평가 기준 최소비용 후보(현재 후보 집합·본 비용 함수 안에서의 최선)와 일치한 비율은 66%(8 시간 창 54%)였고, 결정당 평균 후회(regret)는 기대 이상 0.031 건으로 무작위 선택(0.116)과 최악 선택(0.245)의 사이에서 무작위 대비 개선 여지의 74%를 회수하였다. 개입(유지가 아닌 대응) 99 건 가운데 71%는 유지 대비 공장 전체 비용을 낮췄으며(셋업 재확인 96%, 재할당 65%, 공구 교체 63%, 평균 편익 0.19), 공구 교체와 재할당의 편익이 상대적으로 불안정하였다. 이 어긋남이 종단 성과에 얼마나 반영되는지 확인하기 위해, 매 결정마다 전체 공장 반사실 평가(예측기 기준 4 시간 창 비용)로 후보를 고르는 정책을 10 개 시드에서 끝까지 실행하였다(결정 1,203 건, 전체 공장 재실행 4,029 회). 전체 공장 선행 정책의 이상률은 11.1%로 축약 정책 11.2%와 거의 같았고 짝지은 차이 −0.2%p(95% 신뢰구간 −0.8~+0.4%p, Wilcoxon p=0.78)는 유의하지 않았으며, 공구 교체(40.9 회 대 41.1 회, p=0.88), 순가동률과 납기준수율의 차이도 ±0.2%p 안이었다. 두 정책 모두 예방 교체 규칙(14.4%, 47.2 회) 대비 이상률 −3.2~−3.4%p·공구 −6.1~−6.3 회로(네 비교의 Holm p 모두 0.008) 개선되었다. 즉 후보 선택의 불일치는 종단 성과에는 거의 반영되지 않았다. 다만 이 종단 비교는 10 개 시드의 탐색적 검증이며 주 실험(30 개 시드, Table 7)과 같은 검정력을 갖지는 않는다(7.6 절).

Fig. 15 는 ⑧단계의 필요성을 보인다. 예측기의 계수를 의도적으로 오지정한 상태(마모·셋업 계수 30% 과소, 절편 상향)에서 15 일을 운영하면, 피드백 없이 운영한 제안 시스템은 이상률 16.6%로 예방 교체 규칙(14.8%)보다 오히려 나빠진다. 검사 결과로 재학습하면 이상률이 내려가 15 일 평균 13.8%로 예방 교체를 하회하며, 정확한 모델(12.3%)과의 차이도 절반 이하로 줄어든다. 마모 계수는 2.45 에서 2.91 로 참값(3.5) 방향으로 회복되었으나 완전히 복원되지는 않았는데, 이는 제안 시스템이 마모가 진행된 공구를 정삭 전에 교체하여 고마모 영역의 검사 데이터 자체가 줄어드는 개입의 부작용이다. 즉 페루프의 학습은 자기 개입이 만든 데이터 편향 아래에서 이루어지며, 이를 보정하는 탐색적 관측의 삽입이 후속 과제이다.

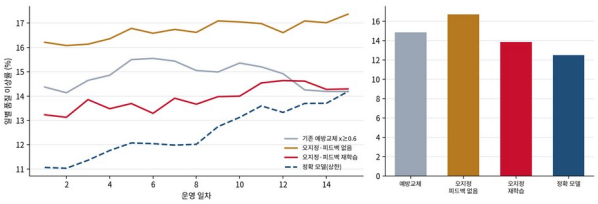


Fig. 15. 예측기 오지정 상태에서 피드백 재학습의 효과(15 일 운영, 30 회 평균). (a) 일별 품질 이상률, (b) 15 일 평균.

시뮬레이터의 두 핵심 가정에 대한 강건성으로, 공구 수명 변동계수를 0.12~0.40, 고장 간격 파라미터를 30~120 시간(라인 평균 대기시간 3.3~13.3 시간)으로 바꾼 9 개 조합 전부에서 제안 시스템은 예방 교체 규칙 대비 이상률 −20~−25%, 공구 교체 −5~−7 회를 유지하였다. 수명 변동계수와 고장 빈도 모두 이득의 크기에 뚜렷한 경향을 만들지 않았다.

6.6 방법의 타당성 검증: 모델 불일치, 예측기 품질, 구성요소 분해

앞선 실험은 시뮬레이터의 실제 위험 함수와 예측기가 같은 로지스틱 형태를 공유하므로, 이득이 "형태를 아는 예측기"의 산물일 가능성(순환성)을 배제해야 한다. Fig. 16 은 실제 위험 함수를 로지스틱 외에 Weibull 누적위험(형상계수 3), 두 임계의 계단형, 마모×공차 상호작용형으로 바꾸고, 예측기는 형태를 모른 채 각 함수가 생성한 표본으로 오프라인 적합한 로지스틱을 그대로 쓴 결과이다. 형태가 틀린 세 경우 모두에서 제안의 τ 스윕 곡선은 고정 임계 규칙의 곡선보다 아래에 놓였고, 예방 교체와 같은 공구 예산에서 보간한 이상률은 로지스틱 −31%, Weibull −27%, 계단형 −28%, 상호작용형 −28%였다(Table 9). 다만 형태가 틀린 예측기는 τ=0.2 의 공구 소모가 65~88 회로 커지므로, τ 는 재학습 때마다 공구 예산에 맞춰 재보정해야 한다.

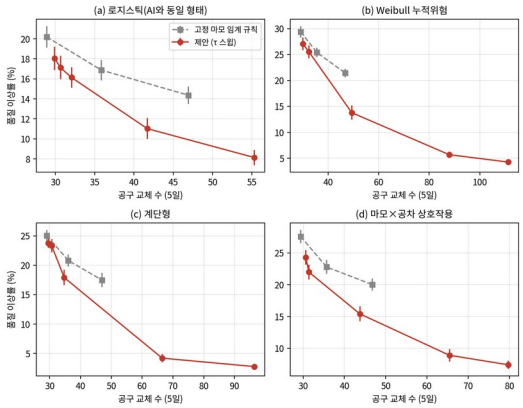


Fig. 16. 실제 위험 함수의 형태를 바꾼 모델 불일치 실험(정상 부하, 20 회 평균, 오차막대 95% 신뢰구간). 예측기는 모든 경우 로지스틱이며 각 함수의 표본으로 오프라인 적합하였다.

Fig. 17 은 5 장의 예측 성능 신뢰구간이 넓다는 한계를 시스템 수준에서 흡수한다. 예측기가 관측하는 마모 진행도에 표준편차 σ 의 오차를 주입해 예측기 품질을 낮추고, 그림자 모드에서 시뮬레이터 결과에 대한 AUC 를 측정하였다(오차 없는 기준 AUC 0.68; 검사 결과가 확률적으로 생성되므로 5 장의 0.89 와 직접 비교되지 않는다). 예방 교체 규칙과 같은 공구 예산에서 제안 시스템의 이상률 감소는 AUC 0.68 에서 −31%, 0.67 에서 −27%, 0.66 에서 −21%, 0.64 에서 −16%, 0.61 에서 −4%로 줄어들었고, AUC 0.58(σ=0.8)에서는 τ 를 어떻게 잡아도 예방 교체와 같은 공구 예산에 도달하지

못하였다. 즉 이득은 예측기 품질에 따라 점진적으로 줄어들 뿐 급격히 사라지지 않으며, 기준 AUC 의 약 90% 수준까지 양(+)의 이득이 유지된다.

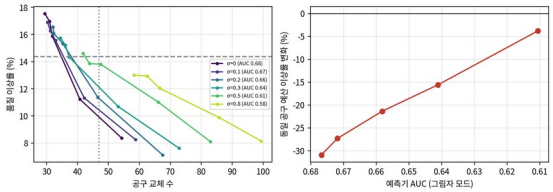


Fig. 17. 예측기 품질에 따른 시스템 이득(정상 부하·고위험, 20 회 평균). (a) 마모 관측 오차별 τ 스윕 곡선, (b) 그림자 모드 AUC 대비 동일 공구 예산에서의 이상률 변화.

구성요소 분해(E11)는 "설명(②)과 사전 검증(④)이 없어도 같은 정책이 가능한가"라는 질문에 답한다. 예측만 두고 τ 초과 시 항상 공구를 교체하는 구성은 이상률 12.2%, 공구 57.5 회로 예방 교체 규칙보다 이상률은 낮지만 공구를 22% 더 썼다. 여기에 ②의 요인별 고정 대응(마모 우세면 공구 교체, 셋업 우세면 셋업 재확인)만 더하면 11.6%, 43.6 회로 개선의 대부분이 나타났고, ④ 를 더한 제안 시스템은 11.5%, 41.0 회로 공구를 2.7 회 더 아꼈다. 한편 ② 없이 ④가 모든 후보를 항상 평가하는 구성은 제안 시스템과 정확히 같은 결정에 도달하였다. 4.4 절의 안전장치는 성능을 바꾸지 않고(ε=0~2 및 항상 전수 평가에서 이상률·공구 교체 동일) 설명이 틀릴 때 행동 선택을 보호하는 역할만 한다. 후보가 세 종류뿐인 본 설정에서는 선행 시뮬레이션이 요인 판단을 대체할 수 있기 때문이며, ② 를 유지하는 근거는 성능이 아니라 담당자에게 제시되는 판단 근거에 있다(7.1 절).

네 가지 설정 가정의 민감도(정상 부하·고위험, τ=0.2)도 확인하였다. 재학습 설정(초기 버퍼 {20, 40, 80}건 × 갱신 주기 {10, 20, 40}건)을 바꾸어 오지정 상태에서 15 일을 운영하면 평균 이상률 13.4~13.8%로 모든 조합이 피드백 없는 경우(16.3%)와 예방 교체(14.7%)보다 낮았고, 셋업 재확인의 불량 제거 확률을 60·80·100%로 바꾸면 12.0·11.7·11.5%, 셋업 불량률 3·6·10%에서는 예방 교체 대비 −18·−21·−28%(셋업 요인이 흔할수록 이득 증가), 초기 마모 분포 U(0, b), b∈{0.5, 0.8, 1.0}에서는 −23~−25%로 결론이 유지되었다.

Table 9. 모델 불일치 실험 요약 (정상 부하, 20 회 평균). "동일 공구 예산"은 예방 교체 규칙의 공구 교체 수에서 τ 스윕 곡선을 보간한 값

실제 위험 함수	사후교체 이상률	예방교체 x≥0.6 이상률 / 공구	제안(동일 공구 예산) 이상률	변화	제안 τ=0.2 이상률 / 공구
로지스틱(AI 와 동일 형태)	20.2%	14.4% / 47.0	9.9%	-31%	11.0% / 41.7
Weibull 누적위험 (k=3)	29.4%	21.4% / 46.8	15.6%	-27%	5.7% / 88.0
계단형(2 임계)	25.1%	17.5% / 47.0	12.6%	-28%	4.2% / 66.5
마모×공차 상호작용	27.6%	20.0% / 46.8	14.5%	-28%	8.9% / 65.5

지금까지의 실험은 셋업 불량을 지능 계층과 정보 동등 규칙이 오차 없이 관측한다고 가정하였는데, 이는 두 정책의 이득 가운데 셋업 정보에 기인하는 부분을 좌우하는 가정이므로 관측 오류에 대한 강건성을 별도로 확인하였다(Table 10). 실제 셋업 상태와 정책의 관측값을 분리하고, 결과를 보기 전에 정한 4 개 수준의 오탐률·미탐률 조합을 두 정책에 같은 부품 단위 난수로 주입하였다(관측값은 부품 시작 시 생성, 재클램핑 뒤에는 정상으로 간주; 정상 부하·고위험·τ=0.2). 오탐·미탐을 함께 바꾼 조합 시나리오이므로 개별 효과나 허용 오류 경계를 추정한 것은 아니다. 정상 부하·고위험 30 회 짝지은 비교에서 이상률의 제안 시스템 우위(정보 동등 대비)는 오류 없음과 낮은 오류(오탐 5%·미탐 20%)에서 유의하였으나(−1.2·−1.7%p, Holm p 0.006·0.0002), 중간 오류(10%·40%)에서 −0.7%p 로 줄어 유의한 차이를 확인하지 못했고, 높은 오류(20%·60%)에서는 점추정치가 −0.03%p 로 작아져 유의한 추가 개선을 확인하지 못했다(효과가 없음을 입증한 것은 아니다). 공구 교체 수는 모든 수준에서 유의하게 감소하였고(−5.0~−5.8 회, p<0.001), 납기준수율은 Holm 보정 후 유의한 차이를 확인하지 못했다. 두 정책 모두 모든 수준에서 예방 교체 규칙(14.6%)보다 이상률이 낮았고, 관측 오류가 커지면서 총 재클램핑 횟수(필요한 조치 포함)는 제안 약 13→47 회, 정보 동등 약 15→54 회로 늘어 오탐에 따른 불필요한 조치가 발생할 수 있음을 보였다. 즉 예측·설명·사전 검증의 이상률 추가 이득은 셋업 관측이 충분히 정확할 때 확인되었고, 관측이 나빠지면 품질 개선의 증거는 약해지되 공구 절감은 유지되었다. 이 결과는 현장 적용 시 클램프 압력 등 셋업 관측 변수의 오탐·미탐률을 먼저 측정해야 함을 뜻한다.

Table 10. 셋업 관측 오류에 대한 강건성 (정상 부하·고위험, 30 쌍; 오탐 = 실제 정상을 불량으로, 미탐 = 실제 불량을 정상으로 관측; 재클램핑은 5 일간 총 실행 횟수(필요한 조치 포함), 실제 셋업 불량 부품은 평균 15 건; Holm 보정은 4 수준×3 지표=12 개 가족; 예방 교체 x≥0.6 은 14.6% / 47.1 회)

관측 오류 (오탐/미탐)	제안 τ=0.2 이상률 / 공구 / 재클램핑	정보동등 x≥0.6 이상률 / 공구 / 재클램핑	이상률 차이 (제안 −정보동등)	Holm p	공구 차이	Holm p
0% / 0%	11.5% / 41.0 / 13	12.7% / 46.7 / 15	−1.20 %p (−9%)	0.006	−5.8 회 (−12%)	<0.001
5% / 20%	11.4% / 41.5 / 21	13.1% / 47.0 / 25	−1.68 %p (−13%)	<0.001	−5.6 회 (−12%)	<0.001
10% / 40%	12.4% / 41.0 / 29	13.1% / 46.7 / 33	−0.67 %p (−5%)	0.093	−5.7 회 (−12%)	<0.001
20% / 60%	13.5% / 42.0 / 47	13.6% / 47.0 / 54	−0.03 %p (−0%)	1.000	−5.0 회 (−11%)	<0.001

6.7 페루프 통합 시험: 장애 주입에 대한 복귀 규칙의 동작

앞의 검증은 하나의 시뮬레이션 프로세스 안에서 이루어졌으므로, 구성요소가 분리되어 메시지로 연결될 때 8 단계 루프가 끝까지 닫히는지와 Table 12 의 복귀 규칙이 실제 장애에서 동작하는지를 별도로 확인하였다. 지능 계층(①②③), CPS 사전 검증 서비스(④), APS·홀론 mock(⑤), PLC 에뮬레이터(⑥), CMM 에뮬레이터(⑦)를 5 개 독립 프로세스로 분리하고 TCP 소켓 위의 JSON 메시지로 연결한 software-in-the-loop(SIL) 환경에서, 결정 주기는 홀론 mock 이 가공 직전 상태를 보내는 것으로 시작해 위험 예측·후보 생성, CPS 호출, APS 반영 확인, PLC 태그 쓰기, 검사 결과 생성, 피드백 반영(⑧)까지 실제 메시지 왕복으로 진행된다. CPS 서비스는 해석적 사전 검증(6.5 절)을 쓰고 검사 결과는 6 장과 같은 위험 함수로 생성하였다. 이 시험은 품질 성능이 아니라 인터페이스 통합 가능성, fail-safe 동작, 프로세스 간 통신을 포함한 종단 지연을 확인하기 위한 것이다.

Table 11 은 정상 결정 주기 1,000 건, Table 12 의 실패 모드에 대응하는 12 종의 장애 시나리오 각 100 건, 검사 라벨을 반전시킨 드리프트 시퀀스 시험 1 회(반전 관측 200 건, 복귀 관측 160 주기)의 결과이다. 통과율의 분모는 장애 대상 구성요소가 실제로 호출된 주기(장애 도달)이며, 예측 위험이 τ 를 넘도록 상태를 강제하여 1,200 건 전부가 장애 지점에 도달하였다. 입력 누락·신선도 초과·범위 이탈은 입력 검사에서 걸러져 AI 개입이 금지되었고, CPS 시간 초과·연결 종료·응답 손상은 대응안 폐기와 기존 계획 유지로 처리되었다. PLC 쓰기 실패·무응답에서는 갱신된 APS 작업오더를 직전 계획으로 복원하는 롤백 메시지를 보낸 뒤 APS 를 조회하여 확인하였고, APS·PLC 장애의 절반(각 50 건)은 "유지"가 아닌 별도 계획을 미리 설정하여 임의의 직전 계획도 복원되는지 비교하였다. APS 거부·무응답 200 건은 계획이 변경 전 값 그대로 유지되었고, PLC 실패·무응답 200 건은 변경 전 계획(유지 100 건, 별도 계획 100 건)으로 복원되었다. 지연 도착 응답이나 재전송에 의한 중복 실행은 시나리오에 포함하지 않았다. 설명이 모호한 상태(기여도 차이 $< \varepsilon$)를 강제한 100 건에서는 모두 네 후보 전부가 사전 검증으로 전달되었다. 드리프트 시퀀스에서는 운영 중 감시(최근 100 건 창의 AUC < 0.50 또는 |평균 예측 확률 − 실측 이상률| > 0.25 가 50 건 연속)가 149 건째에 드리프트를 감지해 그림자 모드로 전환하였고, 재학습 완료 신호 뒤 정상 데이터 100 건이 쌓이자 능동 모드로 복귀하였다. 재학습 완료는 시험 드라이버의 상태 신호이므로 확인한 것은 감지와 모드 전이(능동→그림자→능동)이며, 이 임계값은 SIL 시험 기준이고 정상 주기 1,000 건에서 오탐은 없었다. 시험한 장애 범위 안에서 검증되지 않은 대응이 실행 계층에 전달된 경우는 없었다. 정상 주기의 종단 지연(Fig. 18)은 ①~④ 결정까지 중앙값 1.2 ms·95 백분위 1.9 ms, APS·PLC·CMM·피드백을 포함한 전체 주기 중앙값 8.3 ms·95 백분위 19.2 ms 였다(재현 노트북의 최종 실행에서 기록된 값이며 실행마다 수 ms 범위에서 달라진다). 이는 루프백 측정치로 실제 PLC 네트워크·DB 지연은 포함하지 않으나, 프로세스 분리에 따른 결정 지연이 가공 주기(수십 분)에 비해 무시할 수 있음을 보인다. 실제 PLC·APS 를 연결한 hardware-in-the-loop 시험은 7.5 절의 도입 단계에서 수행되어야 한다.

Table 11. SIL 페루프 통합 시험의 장애 주입 결과 (5 개 프로세스, TCP 메시지; 정상 1,000 + 장애 12 종×100 + 드리프트 관측 200 = 2,400 결정 주기, 복귀 관측 160 주기 별도). "장애 도달"은 장애 대상 구성요소가 실제로 호출된 주기 수이며 통과율의 분모

주입 시나리오	실행	장애 도달	기대 동작(Table 12)	관측 결과(도달 기준)	결정 지연 ms (중앙값 / P95)
정상 결정 주기	1000	1000	개입/유지 정상 완료, 능동 모드 유지	1000/1000 (100%)	1.2 / 1.9
현장 입력 누락	100	100	해당 결정에서 AI 개입 금지	100/100 (100%)	0.3 / 0.4

주입 시나리오	실행	장애 도달	기대 동작(Table 12)	관측 결과(도달 기준)	결정 지연 ms (중앙값 / P95)
입력 지연(신선도 5 s 초과)	100	100	해당 결정에서 AI 개입 금지	100/100 (100%)	0.3 / 0.4
입력 분포 이탈(마모 진행도 범위 밖)	100	100	자동 대응 중단, 기존 규칙	100/100 (100%)	0.3 / 0.4
설명 모호($\lvert S_1-S_2\rvert < \varepsilon$)	100	100	가지치기 없이 전 후보 사전 검증	100/100 (100%)	1.7 / 2.0
사전 검증 시간 초과 (0.5 s)	100	100	대응 폐기, 기존 계획 유지	100/100 (100%)	502.1 / 502.4
사전 검증 통신 오류 (연결 종료)	100	100	대응 폐기, 기존 계획 유지	100/100 (100%)	1.4 / 1.6
사전 검증 응답 손상	100	100	대응 폐기, 기존 계획 유지	100/100 (100%)	1.4 / 1.8
APS 반영 거부(nack)	100	100	기존 계획 유지(조회 검증), 통보	100/100 (100%), 변경 전 계획(유지 50· 별도 50) 복원 확인	1.7 / 2.1
APS 무응답	100	100	기존 계획 유지(조회 검증), 통보	100/100 (100%), 변경 전 계획(유지 50· 별도 50) 복원 확인	1.7 / 2.0
PLC 태그 쓰기 실패	100	100	APS 계획 복원(조회 검증), 통보	100/100 (100%), 변경 전 계획(유지 50· 별도 50) 복원 확인	1.6 / 1.8
PLC 무응답	100	100	APS 계획 복원(조회 검증), 통보	100/100 (100%), 변경 전 계획(유지 50· 별도 50) 복원 확인	1.7 / 2.0
통신 지연 급증(+250 ms, 한계 이내)	100	100	정상 처리	100/100 (100%)	252.1 / 252.4
모델 드리프트(검사 라벨 반전) — 시퀀스 시험 1 회	200 (+복귀 160)	–	감지 → 그림자 모드 → 재학습 후 복귀	149 건째 감지, 그림자 52 건, 복귀 신호 후 능동 복귀	1.2 / 1.8

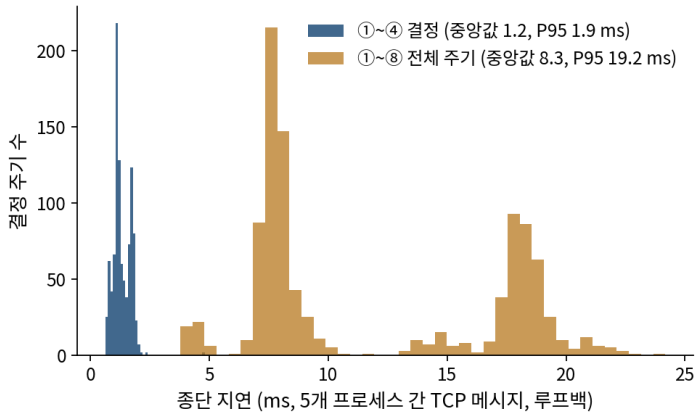


Fig. 18. SIL 시험 정상 시나리오 1,000 결정 주기의 종단 지연 분포(5 개 프로세스 간 TCP 메시지, 루프백).

7. 고 찰

핵심 비교 결과와 범위는 Table 13(7.6 절 끝)에 요약하였다.

7.1 이득의 원천: 단순 규칙과 언제 다른가

고정 임계 규칙은 마모 진행도 하나로 교체를 결정하므로 오퍼레이션을 구분하지 못한다. 제안 시스템은 공차가 엄격한 정삭 직전의 위험 증가를 반영할 수 있으므로 새 공구를 정삭에 배정하고 마모된 공구는 황삭에 계속 쓰며, 셋업이 원인이면

공구 소모가 없는 셋업 재확인을 택할 수 있다. 6.4 절의 비교는 이 이득이 어디까지 단순 규칙으로 설명되는지를 보인다. 예방 교체 대비 차이의 약 60%는 셋업 정보의 활용(정보 동등 규칙)에 대응하고, 오퍼레이션별 임계를 더한 공정별 규칙과 비교하면 정상 부하에서는 유의한 차이를 확인하지 못했고 포화 부하에서는 규칙의 이상률이 유의하게 낮았으므로, 고위험 성과만으로는 지능 계층이 잘 조정된 공정별 규칙보다 낫다고 말할 수 없다. 6.6 절의 구성요소 분해(예측만 12.2%·57.5 회 → 요인별 고정 대응 11.6%·43.6 회 → 사전 검증까지 11.5%·41.0 회; 설명 없는 전수 검증은 같은 결정)도 같은 방향이며, 성과의 원천은 "위험에 맞는 행동을 오퍼레이션별로 고른다"는 조건화이고 이는 규칙·설명·검증 어느 쪽으로도 얻을 수 있다. 지능 계층이 규칙과 다른 점은 결정을 표현하는 방식에 있다. 규칙은 임계값으로, 제안은 예측 확률과 비용 가중치로 결정을 표현하며, 저위험 조건에서는 τ·가중치를 바꾸지 않고도 다른 운용점에 놓였다(6.4 절, Table 8; 단, 그 비교의 예측기는 저위험 함수로 초기화한 것이다). 어느 운용점이 유리한지는 재작업·공구 비용비에 달려 있다(7.4 절). 즉 이번 고위험 조건에서 조정된 공정별 규칙은 경쟁력 있는 대안이었고, 본 연구의 기여는 그 규칙을 이겼다는 것이 아니라 예측·설명·대안 평가·실행 복구를 연결하는 구조를 구현하고 검증한 데 있다. 그 구조의 유지보수·현장 업무 효율·설명 활용 가치는 입증된 것이 아닌 기대 효과이자 후속 검증 대상이며(제안도 예측기 보정과 τ 조정이 필요하다), 현장 도입 시에는 규칙의 성능과 운영 복잡도를 함께 비교해야 한다. ② 의 역할은 성능이 아니라 조치 근거의 제시(기여 요인이 공구 마모인지 셋업인지가 제시되면 가동 중단·소재 폐기 대신 국소 조치를 택할 수 있다)와 판단 기록의 축적에 있으며, 후보 공간이 커질 때의 탐색 축소는 측정하지 않았으므로 가능성으로 남긴다.

7.2 재할당 대응의 역할과 그 함의

재할당은 단독으로는 효과가 작았다(사후 교체 대비 −10%). 동적 배정이 대기열과 마모를 함께 고려하므로 설비 간 공구가 비슷한 속도로 닳아 "더 새 공구"가 드물기 때문이다. 조합에서는 채택된 개입의 31%가 재할당이었으나 대기열이 짧고 공구가 새것에 가까운 설비가 있는 경우에 한정되며, 반사실 평가에서 편익은 셋업 재확인보다 작고 불안정하였다(65%).

7.3 임계값 τ 의 선택

τ 민감도 결과는 이상률과 공구 소모의 상충을 보이며 납기·가동률은 둔감하였으므로, τ 는 재작업 1 건의 추가 비용 C_r(7.4 절과 같이 설비 점유시간을 제외한 값)과 공구 1 세트 비용 C_t의 비율로 정할 수 있다. 실제 선정은 평가한 τ 후보(0.05~0.5) 가운데 정의한 총비용이 가장 작은 값을 고르는 방식이며(6.4 절), 연속 근사에서는 다음의 한계비용 균형이 그 조건에 해당한다.

$$C_r \cdot N_{parts} \cdot |d\Delta q/d\tau| = C_t \cdot |d\Delta N/d\tau| \quad (3)$$

다만 유한 격자·경계점·비선형 비용에서 식 (3)만으로 최적이 보장되지는 않는다. τ=0.2 는 보수적 대표 운용점이며, C_r/C_t가 큰 현장에서는 현장 원가 비율로 더 낮은 τ 를 택할 수 있다.

7.4 시뮬레이션 결과의 연간 환산과 경제성 조건

이 절은 절감액 예측이 아니라 정책 간 차이를 연간 규모(정상 부하·고위험, 연 300 일, 약 15,600 부품)로 환산한 시나리오 분석이다. 예방 교체 규칙(x≥0.6) 대비 이상률 −3.1%p 는 연간 약 480 건의 재작업 회피(재작업 1 건 = 정삭 재가공 55 분 설비 점유 → 약 440 설비시간 회수), 공구 교체 −6.1 회/5 일은 연간 약 370 세트의 절감이며, 정보 동등 규칙 대비로는 약 190 건·350 세트·170 시간이다. 절감액은 단가를 기호로 두면 다음과 같다.

$$\Delta C = N_{rw} \cdot C_r + N_{tool} \cdot C_t + H_m \cdot C_m \quad (4)$$

여기서 N_{rw}는 연간 회피 재작업 건수, N_{tool}은 절감 공구 세트 수(증가 시 음수), H_m은 회수 설비시간, C_r·C_t·C_m은 각각 재작업 1 건, 공구 1 세트, 설비 1 시간의 비용이며, 이중 계상을 피하기 위해 C_r은 설비 점유시간을 제외한 추가 비용으로 정의한다. 예방 교체 대비 (N_{rw}, N_{tool}, H_m) = (480, 370, 440), 정보 동등 대비 (190, 350, 170), 사후 교체 대비 (1,400, −730, 1,280)이다. 앞의 둘은 세 항이 모두 양이므로 식에 포함한 비용 항에 한정하면 단가와 무관하게 양(+)이고(도입·유지 비용은 미포함), 사후 교체 대비는 손익분기 조건 $C_r > (730 \cdot C_t - 1{,}280 \cdot C_m)/1{,}400$, 즉 설비시간 가치를 0 으로 두어도 재작업 1 건 비용이 공구 1 세트의 0.52 배를 넘으면 양(+)이며, 이는 현장 원가로 확인해야 한다. 저위험 설정의 공구 절감(연간 약 1,060 세트)은 셋업 정보를 쓰는 사후 교체 규칙으로도 얻을 수 있으므로 지능 계층에 귀속시킬 수 없다. 이 환산은 명시한 세 비교군에 대한 것이며 조정된 공정별 규칙 대비 경제적 우위를 뜻하지 않는다.

7.5 현장 적용 시나리오

대상 공장은 CMM 데이터 관리, 공구 사용내역 수집, PLC 데이터블록 직접 제어, 전 설비 이벤트 로그를 갖추고 있어 Table 4 의 매핑으로 예측기 입력을 재구축할 수 있으나 현장 분포에 대한 재학습·재보정이 필요하다. 사전 검증은 기존 CPS 시뮬레이터의 선행 테스트에 대응안 주입 인터페이스를 더해 구현하고, 실행은 APS 작업오더·설비 배정 필드의 갱신으로 훌론 규칙 변경을 최소화한다. 도입은 네 단계이다. 1 단계 오프라인 검증(현장 데이터로 재학습·재보정): 시간·

공구·부품 단위 분리 평가, 확률 보정, 입력 변수 가용성 확인. 2 단계 그림자 모드(판단만 기록): 예측과 검사 결과의 일치, 셋업 관측 오탐·미탐률(6.6 절), 예상 경보·개입 빈도 확인. 3 단계 권고 모드(담당자 승인): 추천 수용·거절 사유와 계획 반영·복구 로그 확인. 4 단계 보호된 폐루프(CPS 검증을 통과한 대응만 자동 적용, 오버라이드 유지): 사전에 정한 품질·납기 기준 충족, 개입 범위 제한, 복구 시험 통과. 통과 기준은 현장 품질 책임자와 사전에 정하며, 이 계획은 실증 결과가 아닌 도입 제안이다. 어느 단계에서든 입력 분포가 학습 분포를 벗어나거나 보정 기준을 충족하지 못하면 자동 대응을 중단하고 기존 규칙으로 복귀한다. Table 12 는 실패 모드와 탐지·복귀 규칙이며, 각 실패 모드는 6.7 절의 SIL 시험에서 주입하였다.

Table 12. 지능 계층의 실패 모드와 복귀 규칙

실패 모드	탐지	복귀(fallback)
예측기 확신 부족·입력 분포 이탈	입력 변수 범위·분포 이탈 검사, 그림자 모드 보정 기준 미달	자동 대응 중단, 기존 예방 교체 규칙 적용
설명 모호(상위 두 요인 기여도 근접)	$\lvert S_1 - S_2 \rvert < \varepsilon$ (ε=0.5)	가지치기 없이 모든 대응안을 사전 검증
사전 검증 시간 초과·통신 오류	결정 시간·응답 감시	대응안 폐기, 기존 홀론 규칙 유지
현장 입력 누락·지연	데이터 신선도(freshness) 검사	해당 결정에서 AI 개입 금지
모델 드리프트	운영 중 AUC·보정 지표 감시	그림자 모드로 복귀 후 재학습
APS 반영 실패	작업오더·배정 갱신 확인(acknowledgement) 실패	기존 계획 유지, 담당자 통보
PLC 쓰기 실패·무응답	실패 응답 또는 응답 시간 초과	APS 를 변경 전 계획으로 복원하고 조회로 확인

온도 기반의 기존 폐루프와는 같은 CMM 데이터를 공유하며 서로 다른 원인을 담당하는 상보 관계이다.

7.6 한계

첫째, 공개 데이터는 왁스 소재·소형 장비 실험으로 항공 알루미늄 5 축 가공과 다르며, 표본 91 개로 신뢰구간이 넓다. 둘째, 시뮬레이터의 품질 위험은 가정한 함수로 생성한 것이며(6.6 절에서 형태 4 종·예측기 품질 6 수준 평가), 셋업 불량은 이진 상태, 재작업 후 재검사와 동시 고장은 미모델링, 공통 난수는 고장 배정까지 동기화하지 않는다. 셋업 관측 오류가 크면 이상률의 추가 개선이 확인되지 않으므로 현장에서는 관측 변수의 오탐·미탐률을 먼저 측정해야 하며, 공정별 규칙 비교는 격자 15 개·개발 시드 10 개로 조정한 한 규칙(재할당 미포함)이라 다른 격자·조정 기준에서는 결과가 달라질 수 있다. 셋째, 선행 시뮬레이션은 물류 자원을 생략하고 공구 교체·재작업 중의 잔여 점유를 충분히 반영하지 못하는 축약이며, 후보 간 우열이 약 3 분의 1 에서 어긋났으므로(6.5 절) 물류 상호작용이 큰 현장에서는 실제 CPS 의 전체 공장 선행 테스트로 대체하는 것이 안전하다. 피드백 재학습은 개입이 만든 데이터 편향 아래에서 오지정을 완전히 복원하지 못하였다. 넷째, 온도 영향과 가공 스케일은 기존 폐루프의 영역으로 두었다. 다섯째, 보정 기준인 설비·성과 지표는 미공개 기술자료라 제 3 자 재검증이 제한된다. 여섯째, 모델·피처 선택은 탐색적 절차이며 실험 단위 AUC(0.79)가 구간 단위(0.89)보다 낮으므로 현장 재학습 시 중첩 교차검증이 필요하다.

Table 13. 핵심 비교 결과(위)와 검증 근거별 입증 범위·한계(아래). 정책 비교 행은 별도 표기가 없는 경우 제안 τ=0.2 와 30 개 시드의 짝지은 비교

비교 수준 / 시험	핵심 결과 / 확인 내용	범위·한계
예방 교체 규칙 x≥0.6	고위험 두 조건에서 이상률 −16∼−21%(−2.3∼−3.1%p, Holm p<0.001)·공구 −12%, 납기·가동률 악화 없음	저위험은 공구 −18 회; 상대 비열등 한계 10%(주 분석)에서는 정상 조건만 충족, 포화 조건은 한계를 15%로 완화한 사후 민감도 분석에서 충족
정보 동등 단일 임계 규칙 x≥0.6	정상·고위험에서 이상률 −1.2%p(Holm p=0.005)·공구 −12%; 미사용 시드에서 재현(−1.1%p)	포화·고위험 이상률 차이 미확인, 저위험은 이상률↑·공구↓. 구성요소별 인과 기여율 아님
조정된 공정별 임계 규칙	추가 우월성 미확인(정상 +0.2%p, Holm p=1.0); 포화·고위험에서는 규칙의 이상률이 1.0%p 낮음(Holm p=0.03)	개발 단계 공구 예산 제약하에 선택한 고정 정책 간 비교(동등성 검정 아님), 재할당 미포함; 조정·유지보수 비용 우위 미평가
셋업 관측 오류 증가	시험한 오탐/미탐 10%/40% 및 20%/60% 조합에서 정보 동등 대비 이상률의 추가 개선 증거 약화; 공구 절감(−5∼−6 회)은 유지	오탐·미탐 조합 4 수준(0/0, 5/20, 10/40, 20/60 %), 정상·고위험
가정 변화(위험 함수 형태·예측기 품질·수명 CV·고장 간격)	예방 교체 대비 개선 방향 유지, 예측기 품질은 기준 AUC 의 약 90%까지	검토한 형태·수준의 범위 안

비교 수준 / 시험	핵심 결과 / 확인 내용	범위·한계
[근거] 공개 실측 데이터(밀링 18 실험·91 구간, PHM·NASA)	최고 구성의 구간 AUC 0.89·실험 집계 AUC 0.79, 이진 마모 라벨 제외 현장 가용 구성의 구간 AUC 0.83; 대리 원인 카테고리의 SHAP 합이 양수인 비율 30/31(96.8%; 원인 규명 정확도 아님); 수명을 알고 정규화한 hold-out 공구의 마모 곡선 형상 적합성(수명 예측 검증 아님)	왁스·소형 장비, n=91; 예측기 검증과 시스템 검증은 별개 단계
[근거] 보정 시뮬레이터(운영사 순가동률 지표와 ±1%p 이내 정합)	위의 정책 비교 전부 — 합성 위험 함수와 보정한 예측기로 얻은 정책·시스템 효과	실제 CMM 편차 분포·실제 항공 가공 데이터의 종단 검증 없음; 축약 선행 시뮬레이션
[근거] SIL 장애 주입 1,200 건·드리프트 시퀀스	5 개 프로세스로 분리해도 루프가 닫히고, 시험한 장애에서 설계한 복구 동작(PLC 실패 시 변경 전 계획 복원, APS 거부 시 계획 유지) 확인	루프백 소프트웨어 시험; 안전성 인증·현장 성능 검증 아님

8. 결 론

본 연구는 운영 중인 항공기 구조물 무인 가공공장의 홀로닉 자율제조에 품질위험 예측·요인별 대응·사전 검증·실패 시 복구를 연결하는 8 단계 폐루프 지능 계층을 제안하였다. 보정 시뮬레이터의 30 회 짝지은 비교에서 제안은 고위험 두 조건에서 예방 교체 규칙 대비 품질 이상률을 16~21% 낮추면서(−2.3~−3.1%p, $p<0.001$) 공구 교체를 12% 줄였다. 동일 셋업 정보 규칙 대비로도 정상·고위험에서 이상률 1.2%p·공구 약 12% 감소하였고 포화·고위험의 이상률 차이는 유의하지 않았다. 별도 개발 시드에서 조정한 공정별 임계 규칙과 미사용 시드에서 비교하면 정상·고위험에서 차이가 유의하지 않았고 포화·고위험에서는 규칙이 1.0%p 낮았으므로, 고위험 성과만으로는 지능 계층이 조정된 규칙보다 낫다고 말할 수 없다. 적용 판단 기준은 다음과 같다. 위험 수준이 안정적이고 임계를 조정할 개발 데이터가 있는 고위험 라인에서는 조정된 공정별 규칙으로 충분할 수 있고, 제안 계층은 대응안의 적용 전 검증·실행 실패 시 계획 복구·판단 근거 기록이 요구되거나 위험 수준·비용비가 바뀌어 임계를 다시 고르기 어려운 조건에서 검토할 가치가 있다(이 조건의 우위와 예측기 재조정 없는 이전은 후속 검증 대상). 현장 도입 시에는 셋업 관측 품질을 함께 평가해야 한다. SIL 통합 시험(5 개 프로세스, 장애 12 종 1,200 건·드리프트 시퀀스)에서 설계한 복구 동작을 확인하였고 정상 1,000 주기 루프백 시험의 종단 지연 95 백분위는 19.2 ms 였다. 기여는 새로운 예측 알고리즘이 아니라 운영 중인 홀로닉 자율제조를 대체하지 않고 예측–설명–대응–사전 검증–실행–피드백을 실패 시 계획 복구를 포함한 폐루프로 통합하고, 그 성과 가운데 단순 규칙으로 달성 가능한 부분과 추가 검증이 필요한 부분을 구분한 데 있으며, 입증 범위는 실제 설비의 폐루프 성능이 아니라 시뮬레이션상의 정책 효과와 시험한 장애 조건에서의 계획 유지·복구 동작까지이다(Table 13). 실제 적용에 앞서 현장 데이터로 재학습·재보정한 예측기의 비개입(그림자) 평가, 작업자 승인 아래의 권고 평가, 제한된 설비의 보호된 자동 적용(7.5 절)으로 현장 성능과 외적 타당성을 확인해야 한다. 이는 후속 검증 계획이며, 실제 CPS 를 이용한 사전 검증과 개입 편향을 보정하는 탐색적 관측도 후속 과제이다.

참고문헌

[1] H. Van Brussel, J. Wyns, P. Valckenaers, L. Bongaerts, and P. Peeters, “Reference architecture for holonic manufacturing systems: PROSA,” Computers in Industry, vol. 37, no. 3, pp. 255-274, Nov. 1998.

[2] P. Leitão and F. Restivo, “ADACOR: A holonic architecture for agile and adaptive manufacturing control,” Computers in Industry, vol. 57, no. 2, pp. 121-130, Feb. 2006.

[3] P. Valckenaers and H. Van Brussel, “Holonic manufacturing execution systems,” CIRP Annals, vol. 54, no. 1, pp. 427-432, 2005.

[4] P. Leitão, “Agent-based distributed manufacturing control: A state-of-the-art survey,” Engineering Applications of Artificial Intelligence, vol. 22, no. 7, pp. 979-991, Oct. 2009.

[5] L. Monostori et al., “Cyber-physical systems in manufacturing,” CIRP Annals, vol. 65, no. 2, pp. 621-641, 2016.

[6] F. Tao, H. Zhang, A. Liu, and A. Y. C. Nee, “Digital twin in industry: State-of-the-art,” IEEE Transactions on Industrial Informatics, vol. 15, no. 4, pp. 2405-2415, Apr. 2019.

[7] W. Kritzinger, M. Karner, G. Traar, J. Henjes, and W. Sihn, “Digital twin in manufacturing: A categorical literature review and classification,” IFAC-PapersOnLine, vol. 51, no. 11, pp. 1016-1022, 2018.

[8] E. Negri, L. Fumagalli, and M. Macchi, “A review of the roles of digital twin in CPS-based production systems,” Procedia Manufacturing, vol. 11, pp. 939-948, 2017.

[9] D. A. Rossit, F. Tohmé, and M. Frutos, “Industry 4.0: Smart scheduling,” International Journal of Production Research, vol. 57, no. 12, pp. 3802-3813, 2019.

[10] D. Ouelhadj and S. Petrovic, “A survey of dynamic scheduling in manufacturing systems,” Journal of Scheduling, vol. 12, no. 4, pp. 417-431, Aug. 2009.

[11] X. Li et al., “Fuzzy neural network modelling for tool wear estimation in dry milling operations,” Annu. Conf. Prognostics and Health Management Society, San Diego, 2009.

[12] A. Agogino and K. Goebel, “Milling data set,” NASA Prognostics Data Repository, NASA Ames Research Center, Moffett Field, CA, 2007.

[13] R. Zhao, R. Yan, Z. Chen, K. Mao, P. Wang, and R. X. Gao, “Deep learning and its applications to machine health monitoring,” Mechanical Systems and Signal Processing, vol. 115, pp. 213-237, Jan. 2019.

[14] J. Wang, Y. Ma, L. Zhang, R. X. Gao, and D. Wu, “Deep learning for smart manufacturing: Methods and applications,” Journal of Manufacturing Systems, vol. 48, pp. 144-156, July 2018.

[15] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” Advances in Neural Information Processing Systems, vol. 30, pp. 4765-4774, 2017.

[16] S. M. Lundberg et al., “From local explanations to global understanding with explainable AI for trees,” Nature Machine Intelligence, vol. 2, no. 1, pp. 56-67, Jan. 2020.

[17] I. Ahmed, G. Jeon, and F. Piccialli, “From artificial intelligence to explainable artificial intelligence in Industry 4.0: A survey on what, how, and where,” IEEE Transactions on Industrial Informatics, vol. 18, no. 8, pp. 5031-5042, Aug. 2022.

[18] K. Lepenioti, A. Bousdekis, D. Apostolou, and G. Mentzas, “Prescriptive analytics: Literature review and research challenges,” International Journal of Information Management, vol. 50, pp. 57-70, Feb. 2020.

[19] A. Bousdekis, K. Lepenioti, D. Apostolou, and G. Mentzas, “A review of data-driven decision-making methods for Industry 4.0 maintenance applications,” Electronics, vol. 10, no. 7, 828, 2021.

[20] F. W. Taylor, “On the art of cutting metals,” Transactions of the ASME, vol. 28, pp. 31-350, 1907.

[21] ISO 8688-2, Tool life testing in milling — Part 2: End milling, International Organization for Standardization, Geneva, 1989.

[22] A. M. Law, Simulation Modeling and Analysis, 5th Ed., McGraw-Hill, New York, 2015.

[23] J. Banks, J. S. Carson, B. L. Nelson, and D. M. Nicol, Discrete-Event System Simulation, 5th Ed., Pearson, Upper Saddle River, 2010.

[24] R. G. Sargent, “Verification and validation of simulation models,” Journal of Simulation, vol. 7, no. 1, pp. 12-24, Feb. 2013.

[25] H. S. Kang et al., “Smart manufacturing: Past research, present findings, and future directions,” International Journal of Precision Engineering and Manufacturing-Green Technology, vol. 3, no. 1, pp. 111-128, Jan. 2016.

[26] J. Lee, B. Bagheri, and H.-A. Kao, “A cyber-physical systems architecture for Industry 4.0-based manufacturing systems,” Manufacturing Letters, vol. 3, pp. 18-23, Jan. 2015.

[27] G. E. Vieira, J. W. Herrmann, and E. Lin, “Rescheduling manufacturing systems: A framework of strategies, policies, and methods,” Journal of Scheduling, vol. 6, no. 1, pp. 39-62, Jan. 2003.

[28] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining, San Francisco, pp. 785-794, Aug. 2016.

[29] T. Saito and M. Rehmsmeier, “The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,” PLoS ONE, vol. 10, no. 3, e0118432, Mar. 2015.

[30] T. Wuest, D. Weimer, C. Irgens, and K.-D. Thoben, “Machine learning in manufacturing: Advantages, challenges, and applications,” Production & Manufacturing Research, vol. 4, no. 1, pp. 23-45, 2016.

[31] University of Michigan SMART Lab, “CNC mill tool wear dataset,” Kaggle, 2018.

[32] 대상 공장 운영사, Holonic Smart MES 기술 카탈로그(미공개 기술자료), 2026.

[33] H. Tercan and T. Meisen, “Machine learning and deep learning based predictive quality in manufacturing: A systematic review,” Journal of Intelligent Manufacturing, vol. 33, no. 7, pp. 1879-1905, 2022.

[34] A. P. Madathil, X. Luo, Q. Liu, C. Walker, R. Madarkar, and Y. Qin, “A review of explainable artificial intelligence in smart manufacturing,” International Journal of Production Research, vol. 63, no. 23, pp. 8654-8697, 2025.

[35] M. Orošnjak, F. Saretzky, and S. Kedziora, “Prescriptive maintenance: A systematic literature review and exploratory meta-synthesis,” Applied Sciences, vol. 15, no. 15, 8507, 2025.

[36] V. Karkaria, Y.-K. Tsai, Y.-P. Chen, and W. Chen, “An optimization-centric review on integrating artificial intelligence and digital twin technologies in manufacturing,” Engineering Optimization, vol. 57, no. 1, pp. 161-207, 2025.

[37] 나광호, “[르포] KAI 사천공장서 스마트팩토리 '교과서' 만나다,” 미디어펜, 2019. 7. 22.

[38] S. Genetti, G. Scarton, M. Formentini, and G. Iacca, “An intelligent Digital Twin based on machine learning for interpretable decision-making in manufacturing,” International Journal of Production Economics, vol. 291, 109841, 2026.